

光学衍射神经网络: 架构、训练与未来方向的全面综述

OptoMind

摘要

光学衍射神经网络通过以学习到的相位图案引导的被动光传播取代迭代式电子推理, 从而变革了计算成像; 然而, 其从实验室原型走向可部署的光学人工智能, 关键在于解决物理可实现性约束 (波长敏感性、制造容差、静态与可重构硬件) 与最初推动衍射深度学习的算法灵活性之间的张力。本综述认为, 光学衍射神经网络代表了一种根本不同的计算范式——而不仅仅是数字神经网络的光学实现——其中衍射物理既赋予了独特的能力 (光速下的超低延迟、高能效推理), 也带来了硬性约束 (波长依赖性、固定或缓慢可调的相位分布、有限的非线性)。该领域已从单功能衍射透镜演变为通用可训练光学处理器, 但其进展受限于硬件瓶颈而非算法瓶颈。未来的发展路径需要混合光电协同设计、标准化基准测试协议以及感知制造的训练策略, 即将物理约束视为特征而非事后补救措施。本综述描绘了架构全景, 针对物理可实现性评估了训练范式, 按性能成熟度梳理了应用领域, 并指出了光学衍射神经网络要实现实际应用所必须解决的技术瓶颈。

关键词: 衍射深度神经网络, 光学衍射神经网络, 全光神经网络, 衍射光学元件机器学习, 相位调制神经网络, 多层衍射光学网络, 衍射光学网络的训练, 基于梯度下降的光学神经网络

1 引言

在人工智能对更高计算吞吐量和更低能耗的不懈需求驱动下, 超越传统电子处理器局限的替代计算范式引发了强烈关注。在这些新兴技术中, 光学衍射神经网络 (ODNNs), 也称为衍射深度神经网络 (D2NNs), 已成为一类独特的物理计算机。与传统仅在电子工作流中加速特定矩阵运算的光加速器不同, ODNNs 从根本上用空间变化的相位分布取代了电子权重矩阵。这些系统通过菲涅尔或夫琅禾费衍射实现线性变换, 构建了一种计算架构, 其中波动物理定律直接决定了计算表达能力。早期使用无源 3D 打印衍射层的全光实现展示了这一基础愿景: 复杂函数 (如图像分类) 可以在光速下执行, 且在推理过程中无需主动功耗 [1]。本综述系统地考察了 ODNNs 从理论概念到功能性原型的演变, 评估了其重新定义光学人工智能边界的潜力。

光学深度神经网络 (ODNNs) 的重要性在于其解决了冯·诺依曼瓶颈, 即电子系统中数据在存储器和处理单元之间移动所产生的延迟和能量开销。通过将信息编码在光波前的相位和振幅中, 并通过自由空间传播进行处理, ODNNs 提供了巨大的并行性和超低延迟。最近的理论进展进一步拓展了这一潜力, 证明可以通过优化的衍射处理器利用线性光学近似大规模非线性计算, 从而有效地作为带限非线性函数的通用函数逼近器 [2]。这种能力表明了一条通往超快、节能推理引擎的路径, 适

用于从实时物体识别到全光加密和压缩感知等各种应用。在此机制下, 计算成本在很大程度上与操作复杂度解耦, 而是由光在器件中的物理传播时间决定。

然而, 从理想化仿真到稳健的物理部署的过渡充满重大挑战, 这些挑战削弱了上述理论优势。ODNN 研究中的一个核心张力在于”非线性瓶颈”: 尽管无源衍射层擅长线性变换, 但它们缺乏深度学习架构所需的内在非线性, 除非辅以外部机制或混合电子接口。此外, ODNN 的保真度严重依赖于其物理实现的精度。“仿真到现实”(simulation-to-reality) 的差距仍然是一个普遍存在的障碍, 标量衍射模型预测的性能会因制造公差、表面粗糙度和材料色散而在物理原型中下降。弥合这一差距需要复杂的训练范式, 例如硬件在环优化 (hardware-in-the-loop optimization), 其中物理设备被包含在训练循环中以考虑现实世界的不完美性 [3]。此外, 许多已制造平台的静态特性——如 3D 印刷聚合物或光刻定义的超表面——形成了”一次性写入”硬件, 缺乏动态计算环境所需的可重构性。虽然基于液晶空间光调制器 (SLMs) 的可重构平台提供了适应性, 但它们通常在开关速度、功耗和衍射效率方面引入权衡 [4]。

本综述对 ODNN 领域进行了全面的学术分析, 结构上旨在引导读者从基础物理原理走向未来的研究轨迹。我们首先确立衍射神经层的物理架构, 明确界定衍射物理与非线性约束之间的相互作用。随后, 我们评估优化这些系统所需的训练范式, 强调能够缓解仿真到现实差距的物理感知算法。讨论接着进入硬件实现环节, 比较静态和可重构相位调制平台及其在分辨率、带宽和成本方面的各自权衡。我们进一步将波长复用隔离为一个关键自由度, 区分其作为色差约束以及多功能计算使能器的角色。随后, 我们评估 ODNN 在成像和模式识别应用中的成熟度, 严格区分概念验证演示与可部署解决方案。综述最后对声称的计算优势相关的未决争议进行批判性考察, 并以混合电光协同设计的路线图结束。通过综合这些维度, 本研究旨在阐明光学人工智能的现状, 论证虽然 ODNN 提供独特的物理优势, 但其未来的成功取决于与电子系统的战略集成, 以克服固有的物理局限性。

2 衍射神经层的物理架构: 从衍射透镜到可训练光学网络

通过用空间变化的相位分布取代电子权重矩阵, 并借助菲涅耳或夫琅禾费衍射对光进行调制, 衍射深度神经网络 (D2NN) 从根本上重新定义了计算。[1] [5] 在这一物理范式中, 线性变换并非通过离散算术执行, 而是源于由傅里叶光学支配的波传播过程; 在此过程中, 光场根据衍射积分在自由空间和相位调制层之间演化。具体而言, 每一层的复振幅场计算为前一层场的傅里叶变换, 经相位分布调制后, 再沿轴向距离传播, 从而在前向传播过程中无需有源功耗即可有效近似矩阵 - 向量乘法。[6] 该架构利用光的固有并行性, 解决了摩尔定律在能耗和扩展性方面的局限, 能够实现针对生物学细胞分类等任务的实时、高效推理。虽然传统数字系统依赖串行处理, 但 D2NN 利用级联的纯相位调制面执行全光信号处理; 尽管其在速度和效率方面具有独特优势, 但其仿真精度目前可能仍落后于电子 counterparts。因此, ODNN 代表了一种独特的物理计算机, 其计算表达能力由衍射定律决定。对无源衍射的依赖将操作固有限制在线性域内, 形成了一个根本性瓶颈, 从而 necessitates 后续探讨的混合光电解决方案。这一局限性为理解这些抽象相位分布如何在材料层面得以实例化奠定了基础。[7] [8] [9] [10] [11] [12] [13]

要将抽象的衍射积分数学转化为功能性硬件, 必须将衍射神经网络的光学权重物理实例化为空间变化的相位分布。这种物理实现通常依赖于多层薄膜结构, 即一种由堆叠材料层构成的光子平台, 其厚度范围从几十纳米到几百纳米不等。[14] [15] 在这些系统中, 通过优化材料与层厚的特定组合来控制光干涉, 从而产生计算所需的精确相移。虽然利用传输矩阵法等方法计算前向光学响应较为直接, 但为实现特定计算功能而确定最优物理结构却构成了一个复杂的逆设计问题。现代方法通过采用深度学习模型, 将目标光学响应直接映射到结构参数, 从而有效实现了这些可训练光学基底的自动化构建。作为薄膜的补充, 全介电超表面提供了一种替代架构, 其由亚波长尺度的光学天线组成, 通过电磁共振操控散射波。[16] [17] 这类基于超表面的衍射深度神经网络 (D2NN) 通过一系列无源衍射层对输入相干光场进行调制来处理信息, 其中每一层都充当一组独立的相位与振幅调制单元集合。通过误差反向传播对这些单元的分布进行逆优化, 此类网络能够近似输入场与输出场之间任意的复值线性变换。然而, 依赖于厚度调制单元的传统实现方案往往面临与工作波长相当的分辨率极限, 这凸显了制备简便性与先进超表面几何结构所提供的微型化潜力之间的权衡。[18] [19]

单平面衍射光学元件 (SPDOEs) 能够实现紧凑的成像系统, 克服了传统多透镜装置对空间的苛刻要求, 然而其计算表达能力从根本上受到单次衍射事件物理机制的限制。在具有硬圆形光阑的二维网络中, 点扩散函数由第一类贝塞尔函数描述, 其傅里叶变换在光阑孔径范围内保持平坦, 从而确立了刚性的空间频率响应, 限制了单层结构所能执行的变换复杂度。为了突破这些局限, 衍射深度神经网络 (ODNNs) 利用级联衍射面上的衍射效应来执行任意函数, 使其区别于单层对应结构。[2] 这些多层架构在泛化能力和特定应用设计方面提供了显著更优的性能, 利用无源光子传播以光速执行机器学习任务, 同时保持低能耗。然而, 这种增强的能力也引入了与实际制造复杂度及对光 - 机对准极度敏感相关的挑战; 除非在训练阶段通过针对物理变化的“接种”策略专门加以解决, 否则即使是微小的层间错位也会导致性能下降。从静态单一元件向可训练级联结构的转变, 为理解如何将梯度下降直接应用于物理参数以优化这些复杂光路奠定了基础。[20] [21] [22] [23] [24]

为实现多层级联结构的通用近似能力, 物理实现必须具备优化各层相位分布的机制。这一目标通过衍射传播的可微性得以达成, 使得基于梯度的训练能够直接利用输入 - 输出数据来调整元原子尺寸和层间距等物理参数。[25] [26] 在实践中, 前向传播模型利用局部周期假设等近似方法来模拟 ODNN 中的光场传输: 每个元原子在入射电场引入特定的相位调制后, 经由近场至远场的变换将波传播至后续层级。尽管早期设计常通过仅考虑具有固定透过效率的相位调制来简化这一过程, 但 ODNN 研究的发展已凸显出被动固定架构的局限性, 即此类架构一旦制备完成便无法针对新任务进行重新训练。虽然已有研究探索利用空间光调制器构建可编程节点以引入可调谐性, 但这类反射型方案往往限制了层数, 或引入了破坏光速计算能力的电子延迟。因此, 现代可训练架构日益聚焦于透射型配置, 在该配置中相位和振幅调制均可在训练过程中得到优化, 从而在保持全光学系统固有的超低延迟特性的同时, 增强了计算表达能力。[27] [28]

在先前建立的 trainable 设计方案 (可训练设计) 基础上, 先进的架构变体体现在利用额外的物理自由度来提升计算密度和功能。偏振复用使得单个衍射网络能够通过将不同任务编码到不同的输入和输出偏振态中, 在同一视场下同时实现一组复值任意线性变换。[29] 与采用多个专用子系统相比, 该光学架构在速度、通用性和紧凑性方面具有显著优势, 仅需添加线性偏振器而无需改变核心衍射

架构。作为补充, 二维光子晶体衍射神经网络 (PhC-DONNs) 通过多波长处理实现了片上并行分类方案, 通过建立联合波长-衍射调制模型, 克服了传统单波长模式的固有局限性。然而, 纯全光系统通常面临复杂光学设置和缺乏高效非线性激活的挑战, 这推动了混合光电工作流的发展。在这些混合配置中, 优化的衍射光学元件可以实现对颜色敏感的核函数, 以保留通常在窄带滤波中丢失的光谱信息, 而电子组件则处理非线性和自适应训练。这种混合化简化了物理架构, 并允许在不移动部件的情况下实现可重构权重, 弥合了光传播的超低延迟与电子控制的灵活性之间的差距, 从而推进了基于光的神经计算范式。[29] [30] [31] [32]

混合架构扩展了功能模式, 但衍射神经网络的物理实现仍受限于严格的理论极限和环境脆弱性。阿贝-瑞利衍射极限对空间分辨率施加了基本约束, 阻止传统远场系统解析微观和纳米尺度特征, 除非借助无法穿透生物样本的近场探针, 或依赖精确干涉图案的复杂超振荡设计。除了这些理论边界外, 实际实施还面临重大的稳定性挑战; 谐振器虽然有利于引入必要的非线性激活函数, 但对温度波动和机械振动高度敏感, 这会降低性能。同样, 衍射元件和干涉仪需要精确对准, 且容易引入噪声, 导致高精度制造成本高昂且操作困难。为了弥合理想化数学模型与这些物理现实之间的差距, 硬件在环 (HIL) 方法已成为一种关键的设计策略。通过将实际光学硬件作为黑盒组件嵌入优化循环中, HIL 方法考虑了未建模的波前误差和系统差异, 从而实现了消色差扩展景深成像仪等复杂系统的稳健设计。最终, 承认这些限制对于将 ODNNs 从敏感的实验原型转变为可靠的计算范式至关重要, 其中波动物理学既决定了能力也决定了局限性。[33] [34] [35]

尽管存在前述的物理约束和环境敏感性, 衍射神经网络 (D2NNs) 提供了一种独特的计算范式, 其特征为超低延迟、大规模并行性和固有的能效。与受限于内存和处理器之间数据搬运冯·诺依曼瓶颈的电子系统不同, D2NNs 利用光传播以光速执行矩阵向量乘法, 功耗极低, 因为衍射和相位调制自然发生, 无需额外能量消耗。这种架构支持高吞吐量处理, 适用于实时边缘应用, 例如自动驾驶中的全光图像分割, 其中直接访问光学自由度消除了数字预处理的需求。此外, 硬件结构和软件算法的协同设计使得单一物理架构能够支持多功能操作; 通过结合学习的结构化照明或利用双波长差分信号, 这些网络可以在分类和光束转向等不同任务之间切换, 或捕获多尺度空间特征, 而无需物理重构。虽然传统的单波长设计在特征提取方面面临局限, 但高级框架证明, 协同互补的光学响应可以显著提高准确性和抗噪鲁棒性。因此, ODNNs 不仅仅作为加速器, 而是作为多功能物理计算机, 其中衍射定律决定了速度、并行性和多功能性的独特平衡。[36] [37] [38] [39] [40] [41]

利用前文所述的超低延迟和并行性, 衍射神经网络在专用成像与安全任务中展现出独特效用, 在这些任务中, 物理波操纵取代了数字后处理。在安全应用中, 物理信息驱动的衍射网络可近似散射介质的逆传输矩阵, 从而实现散斑密文的高速全光解密。通过直接作用于光场的振幅和相位, 这些系统消除了光电转换固有的延迟, 尽管其重建质量从根本上仍受限于系统的空间带宽积以及对对准误差的敏感性。同样, 在压缩感知中, 机器学习算法利用大规模标注数据集优化光学架构, 以显著少于传统成像所需的探测器单元数量执行特定任务分类。虽然单片棱镜阵列相较于数字微镜器件可能引入模糊, 但得益于高辐射通量, 这两种架构在低信噪比条件下均能实现更优的分类精度。此外, 深度学习的进展正加速全息术向生物医学领域的转化, 实现了高帧率的无标记活细胞成像。尽管这些方法需要精心配准的训练数据以避免伪影, 但显微仪器所提供的精确控制为正则化网络收敛提供

了理想框架。综上所述, 这些应用表明, 光学衍射神经网络 (ODNNs) 既是加速器, 也是独特的物理计算机, 其中衍射定律决定了计算表达能力, 通过牺牲固定权重和波长依赖性, 换取了面向特定领域任务的空前速度与能效。然而, 要在实践中实现这一潜力, 仍需严谨的训练方法和能够应对这些物理约束的硬件实现。[42] [43] [44]

3 光学衍射网络的训练范式: 基于梯度的学习、端到端优化与物理感知算法

继前文讨论光学衍射网络的应用之后, 有必要重新审视使其物理实现成为可能的基础训练范式。端到端可微分训练通过将物理光传播视为适用于梯度下降的计算图, 确立了优化光学衍射神经网络的基础机制。[45] [46] 在该框架中, 超表面层的相位分布作为可训练参数, 通过控制正向波行为的标量衍射积分进行反向传播更新。[47] 该系统不依赖启发式设计, 而是利用随机梯度下降等算法最小化特定任务的损失函数, 从而使网络能够直接学习如何调制光场。该实现利用高效的傅里叶光学方法 (如角谱理论或瑞利 - 索末菲理论) 来建模层间的干涉与衍射, 在计算速度与光传播的物理现实之间取得平衡。这一框架的可行性已由首个全光学衍射深度神经网络得到确证; 该网络运用上述原理, 利用完全通过仿真优化的 3D 打印相位掩模, 以接近光速的速度对手写数字进行分类。通过将衍射物理直接嵌入优化循环, 该方法弥合了抽象机器学习与实体光学硬件之间的鸿沟, 为评估由此产生的计算效率奠定了基础。[8] [48] [27] [11] [49]

衍射深度神经网络 (D2NN) 框架建立在先前确立的可微分训练基础之上, 通过利用这些优化的物理结构实现全光学机器学习; 其中, 特定任务的信息处理完全通过在连续无源层间调制相干光场来完成, 无需任何电子中间步骤。该框架利用了光传播固有的并行性, 通过自由空间衍射以光速执行计算, 相较于传统电子方案, 在吞吐量和能效方面具有显著优势。底层物理过程的可微分特性使得能够通过反向传播优化数百万个人工神经元, 从而支持多任务学习等复杂操作: 在此类操作中, 部分物理层被共享, 既降低了硬件复杂度, 又保持了系统的鲁棒性。近期的进展 (包括双波长差分网络) 表明, 利用互补的光学响应可以显著提高分类精度及抗噪声鲁棒性, 验证了计算速度提升数个数量级的潜力。然而, 尽管这些系统有望为从物体识别到逻辑计算等各类应用提供超高密度计算能力, 但其实际部署最终必须解决针对物理对抗攻击的脆弱性, 以及静态衍射元件固有的可重构性挑战。[19] [50] [39] [51]

尽管全光推理在理论上具有高效性, 但显著的仿真与现实差距往往削弱片上方案的性能, 尤其是基于超表面的方案, 其加工误差会导致物理性能偏离理想化的数值模型。为弥合这一差异, 研究人员采用硬件在环 (HIL) 训练方法, 该方法将物理光学装置直接集成到优化循环中, 而非仅依赖数学传播模型。在此策略下, 硬件充当黑盒前向模型; 例如, 利用可编程相位空间光调制器 (SLM) 进行的端到端设计, 通过将重建图像与真实目标拟合来优化超参数, 从而有效吸收那些难以通过数值建模的波前传播误差。硬件在环自由空间光计算以及面向成像的多色多级衍射光学元件的优化, 展示了这种通过物理反馈而非纯仿真来优化衍射元件的设计思路。[52] 然而, HIL 训练的成功关键取决于精密的机械对准和能量分布控制。对可调液晶延迟器的评估表明, 即使透镜功能间存在微小的

未对准,也会导致光斑能量和聚焦的显著降低,因此需要在优化过程中实时监测探测器图样以校正低阶像差。通过这些物理约束直接嵌入学习循环,HIL 方法确保了所得的衍射网络能够对物理实现中不可避免的缺陷保持鲁棒性。[53] [34] [54]

物理信息优化策略将制造约束和光谱色散显式地嵌入损失景观中,以确保设计的可实现性,从而解决了通过硬件在环方法校正物理误差的需求。所提出的网络将多层薄膜结构的逆向设计不仅视为数据拟合问题,更视为一种组合优化问题,其目标是在遵守物理极限的前提下,识别出能够满足所需光学响应的最佳材料与厚度组合。通过引入色散公式(如 Sellmeier 方程)并对多波长目标进行加权,这些策略能够在管理纳米级精度堆叠层的非平凡复杂性的同时,校正像 Zernike 项之类的像差。然而,此类设计的成功受到制造变异性的严格限制,这种变异性给宽带衍射神经网络的性能引入了显著的不确定性。证据表明,在较短波长下,输入波长的微小差异会放大结构误差,导致在区分间隔紧密的光谱带时分类准确率低下。此外,材料属性设定了硬性物理边界;例如,溶胶-凝胶聚合物的固体外壳需要油浸配置,这限制了可制造的层数,阻碍了原本可能缓解这些误差的深度增加。为了克服这些刚性约束,数据驱动的逆向设计框架利用可微分神经模拟器,将超表面几何结构直接映射到其光谱响应。该机制用高效近似替代了传统计算昂贵的电磁求解器,实现了光学编码器与计算重建网络的联合端到端优化。[55] [56] 这种协同优化已被证明能显著提高光谱保真度及对测量噪声的鲁棒性,表明弥合仿真与现实之间的差距不仅需要更好的训练算法,更需要内在尊重制造与衍射物理规律的损失函数。[18] [57] [55]

替代训练范式旨在解决由离散器件映射引起的梯度链根本性断裂问题,并与将制造约束嵌入损失函数的物理感知正则化方法形成互补。直接将离散映射插入可微光学神经网络的反向传播过程中会破坏优化过程,因为模拟光学器件表现出非均匀响应和周期性相位约束,而数字仿真往往忽略这些特性。为了保持模型的可训练性,物理感知可微协同设计框架利用 Gumbel-Softmax 等技术,无论器件的数字表示格式或范围如何,均能实现完全可微的离散映射。除了基于仿真的校正方法外,原位光学反向传播直接在物理系统中实施学习算法,基于光互易性通过测量前向和后向传播的光场来计算梯度。该配置已在衍射光学神经网络中得到验证,使网络能够自适应系统缺陷并以光速执行推理,尽管这需要精确的光学测量能力。[58] 对于全光复杂度令人望而却步的场景,混合策略提供了一种折中方案;一种新型非线性泛化框架通过整合电子层并利用知识蒸馏,在不增加额外非线性物理元件的情况下提高了混合网络的分类精度。类似地,仅训练电光转换 (OTEOC) 策略将衍射神经网络架构简化为具有光学读出的单层光学结构,在电光编码过程中内在集成非线性函数,从而避免缓慢的光电转换。[32] 在混合光电卷积神经网络的频谱管理背景下,会出现特定的权衡:虽然可以通过窄带滤波器实现单色图像,但重要的颜色信息将会丢失。为了缓解这一问题,可以光学实现颜色敏感型卷积核,或利用色差提取颜色信息,这有望通过高光谱成像技术得到增强。这些多样化的方法共同弥合了理论可微性与物理可实现性之间的差距,确保光学衍射网络在硬件非理想条件下仍保持计算有效性。[45] [58] [22] [32] [31]

先进的优化范式如今利用特定的物理自由度来构建可重构且多功能的衍射网络,从而克服了训练中基本可微性断裂及非理想性所带来的根本问题。一种主要方法是偏振复用,它通过将不同任务编码到不同的输入和输出偏振态中,使单个静态衍射网络能够在同一输出视场内同时执行多个复值

任意线性变换。与部署多个专用子系统相比,由此产生的设计在速度、通用性和紧凑性方面具有显著优势;其仅需添加作为预确定超参数的线偏振片,而无需改变核心衍射架构。除偏振外,超表面的多维光调制能力促进了波长复用计算,其中可重组的分层结构支持跨不同光谱通道的并行操作,如光学加密和多任务分类。尽管早期实现在器件体积与并行精度之间面临权衡,但对高度图和可插拔组件的严格联合优化正在解锁紧凑且高度并行的处理器。作为对这些自由空间方法的补充,二维光子晶体衍射光学神经网络 (PhC-DONN) 集成了片上并行分类方案,通过建立波长 - 衍射联合调制模型,实现了多波长并行处理。这种特定架构克服了传统工作在单波长模式下的片上衍射网络的固有局限性,并在实时多目标跟踪 (利用波长编码的空间坐标服务于自动驾驶) 以及病理切片的三维重建 (利用波长维度映射深度信息) 等应用中展现出潜力。此外,可编程数字编码超表面的集成解决了被动制造器件固有的刚性问题,允许对超原子状态进行动态控制,从而实时实现逻辑门和置换操作等可重构功能。这些复用和可编程技术共同弥合了固定仿真模型与适应性物理现实之间的差距,确保光学神经网络能够从单任务演示器演变为能够处理现实世界部署所需高维复杂性的多功能平台。[29] [59] [28] [30]

利用可重构架构的多路复用能力,端到端可微分训练现已扩展至需要抵抗物理无序并进行复杂场景解释的高维任务。这种可扩展性的一个主要示范是通过未知随机散射体的全光推理: 宽带单像素衍射网络学习相位分布以补偿散射,且无需外部计算能力。该光学架构在针对训练期间从未遇到过的全新散射体进行手写数字分类时,实现了约 88.53% 的盲测准确率;通过利用波长复用信息容量,其性能显著优于单色设计。除分类之外,这些范式还延伸至自动驾驶中的像素级分割,利用具有光学跳跃连接的架构直接在光域处理 RGB 通道,从而实现准确的车道检测。衍射网络的多功能性进一步拓展至专用传感领域,例如无线信号的到达方向估计;在这些应用中,它们以光速调制电磁波,克服了传统电子处理器的延迟和硬件复杂性。与上述识别和传感任务不同,物理信息衍射神经网络能够通过近似散斑图案的逆传输矩阵,实现密文的高速全光解密。这一能力使得能够从散斑场中实时直接还原秘密图像,有效消除了传统方法中光电转换和后处理所固有的计算延迟。此外,将物理先验与深度学习相融合,可实现紧凑的单平面成像系统,从频域 - 空域特征重建高质量图像;而偏振依赖超表面则引入位置感知能力,从而同时区分图案及其空间位置。这些进展证实,成功的 ODN 训练不仅依赖于反向传播,更依赖于能够弥合仿真与现实差距的物理感知策略,以解决复杂的现实世界问题。[60] [36] [61] [21] [62] [42]

4 衍射神经网络的硬件实现: 相位调制平台、制造技术与可重构性权衡

衍射神经网络 (D2NNs) 从理论构想走向实体实现的演进,利用了光衍射固有的并行性和能效优势,以接近光速的速度执行推理。与在矩阵乘法期间受限于内存瓶颈的电子对应物不同,这些全光系统利用自由空间互连,使计算在光通过结构化层传播时自然发生。早期的演示通过采用太赫兹源和 3D 打印衍射光栅成功对图像进行分类,确立了这一框架,证明了光学计算可以在推理阶段无需主动能耗的情况下实现超低延迟。例如,基于神经网络的设计已被用于创建具有双焦点的太赫兹衍射光学元件,展示了此类被动系统在特定信号处理任务中的能力。[63] 然而,D2NN 的物理实现涵

盖了多样化的硬件平台,从静态印刷相位板和光刻制造的多层结构,到动态可重构的空间光调制器 (SLMs) 和超表面。虽然静态元件提供了简单性和能效,但使用 SLM 或数字微镜器件的动态系统能够实现复杂的非线性网络节点和自适应学习,尽管这增加了系统复杂性。静态制造的效率与可重构组件的灵活性之间的这种根本张力定义了当前的硬件格局,直接影响 ODN 能否从仿真扩展到稳健部署。[64] [49]

增材制造已成为物理实现衍射深度神经网络 (D2NNs) 的主要途径,其中 3D 打印的相位结构所展现的实验性能与数值模拟高度吻合。这种快速原型制作的可行性得到了基于溶液的化学方法 (如溶胶-凝胶工艺) 的补充,后者为制备具有可调折射率的大面积多孔薄膜提供了可扩展且低成本的替代方案,这与光刻技术的高精度但高复杂性形成鲜明对比。涂覆工艺的几何细节也至关重要:在定向沉积中,基底的几何形状会导致入射角产生巨大差异,从而直接影响薄膜厚度的均匀性和密度。通常,垂直于入射沉积通量的表面由于具有更大的厚度和体密度而表现出最高的压应力水平;而大角度倾斜特征则显示出较低的密度和厚度,导致界面应力降低;这种变异性增加了应力补偿型精密光学元件的设计难度,并影响了实际衍射光学元件中可实现的相位轮廓保真度。为了进一步降低制造门槛,简化型光学衍射神经网络采用了 2 级别的量化逐像素相位调制,以牺牲部分分类精度为代价,显著降低了制造复杂度,同时保持了图像分类等任务的稳健计算能力。尽管这些静态方法利用宽场光学元件实现了向数亿神经元规模的成本效益扩展,但它们本质上缺乏主动系统的动态适应性,这为高分辨率介电超表面的发展奠定了基础,后者旨在解决传统全息术和增材方法的分辨率极限。[1] [65] [66] [67]

增材制造可实现可扩展的静态 fabrication,但往往产生的神经元尺寸与波长相当,从而限制了分辨率并引入高阶衍射。为克服这些限制,基于超表面的衍射神经网络利用亚波长像素分辨率,以传统厚度调制器无法企及的精度调控振幅和相位的空间分布。全介电超表面作为实现这些网络的物理硬件平台,通过 exploiting 电磁共振的光学天线阵列对相干光场进行调制来处理信息。该架构为电子系统提供了一种替代方案,具备固有的并行性、高能效和低延迟优势,且无需外部电源即可实现相位调制。通过将单个神经元尺寸减小至远小于波长的尺度,全介电超表面实现了完全静态的方案,消除了高阶衍射并最大化了空间利用率。代表性应用包括紧凑型光学逻辑门,例如 1 位半加器和全加器,展示了在机器人和智能传感器等空间受限领域实现小型化、高密度全光计算的可行性。具体实现包括设计为 1 位加法器的全介电超表面基衍射神经网络,彰显了其在执行基本算术运算方面的光学实用性。[19] [48] [19] [68]

可重构系统,如空间光调制器 (SLMs) 和集成可重写超表面,使得灵活计算所需的动态任务切换成为可能,尽管静态超表面具有效率优势。[4] [69] 空间光调制器是一种用于可重构相位调制的动态设备,通常作为衍射光学元件的可编程平台。然而,部署这些网络揭示了仿真与现实之间的差距,制造缺陷和设备非理想性导致训练性能相比理想模型有所下降。例如,利用相变材料的片上可重写超表面会因制造工艺而产生误差,如损耗增加或对晶体棒的空间控制有限,这需要补偿策略。为了弥合这一鸿沟,硬件在环 (HIL) 方法将物理测量反馈直接纳入训练过程。该实现将硬件视为黑盒系统,允许对诸如 SLM 相位图案等参数进行端到端优化,而无需波前传播的显式数学梯度。通过使用进化策略使重建图像拟合真实目标,HIL 设置有效地模拟了数值难以捕捉的差异。然而,这种适应性

伴随着权衡；原位训练可以通过擦除和写入衍射单元来纠正错误，但对迭代物理反馈的依赖以及可重构材料固有的损耗凸显了定义硬件选择格局的灵活性与运行效率之间的张力。[53] [34]

通过物理感知协同设计弥合仿真与现实的差距，对于成功部署具备自适应能力的可重构系统至关重要。该方法论之所以关键，是因为将离散物理器件响应直接映射到衍射光学神经网络中会破坏标准反向传播所需的梯度链；模拟光学组件表现出的非均匀性和周期性相位约束往往是数字模型所忽略的。为解决这一问题，可微协同设计框架采用能够在尊重硬件物理极限（如 2π 的相位调制周期性）的同时实现完全可微离散映射的技术。除了离散化问题外，当网络仅基于理想数值模型进行训练时，表面粗糙度等制造缺陷会进一步降低性能；物理感知的粗糙度优化通过将制造误差直接纳入训练循环来缓解精度损失。在此基础上，原位光学反向传播允许基于光互易性测量前向和后向传播场，从而直接在光学装置内对网络进行训练。该策略同样规避了数字算法庞大的计算开销，使系统能够自我适应固有的硬件非理想性，确保从仿真到物理实现的过渡同时保持能效和推理精度。[45] [70] [58]

除了制备非理想性之外，已部署衍射系统的工作稳定性从根本上受到环境敏感性和相干性要求的制约。光子神经网络谐振器虽能提供有利于实现激活函数的非线性行为，但仍易受温度波动和机械振动的影响，从而对其性能产生不利影响。同样，衍射光学神经网络的工作稳定性依赖于准单色照明条件，即相干长度需超过层间最大光程差；而在涉及非相干光的实际应用中，这一假设可能并不成立。这些挑战在多层架构中尤为显著：尽管此类设计提供了更好的泛化能力，却引入了显著的光机对准敏感性，其中物理失配会降低训练相位分布的计算保真度。为解决这一问题，近期策略采用了一种“免疫训练”训练方案，在优化过程中将层间失配建模为连续随机变量，使网络即使在 x 、 y 和 z 方向发生严重位移时仍能保持物体识别准确率。最终，选择硬件平台需要在这些稳定性约束与应用需求之间取得平衡，因为即使是经过鲁棒训练的模型，也必须在严格的物理界限内运行，才能成功从仿真过渡到实际部署。[33] [71] [23]

为满足运行稳定性的需求，当前先进的集成策略利用片上逻辑和复用技术，在保持鲁棒性的同时最大化计算密度。可见光谱范围内的超表面衍射神经网络利用复用相位分布，与自由空间实现相比，实现了紧凑、静态的硬件实现，具有高分辨率和低功耗。这种微型化延伸至超紧凑型微尺度光学逻辑运算，其中通过双光子聚合打印的三维衍射结构可以在仅 $100 \times 100 \times 50 \mu\text{m}^3$ 的体积内以 100% 的精度执行多种逻辑门，直接解决了传统电子系统的带宽和功耗限制。级联衍射架构通过规避对显式非线性电子激活函数的需求，转而依靠光学调制和自由空间传播，利用数字与衍射相位丢弃机制之间的等效性来实现计算深度，从而进一步解决系统约束。为提高吞吐量而无需机械重配置，多波长架构将不同任务编码到独立的光谱通道中，允许同时对不同数据库进行分类，同时保持单个任务的准确性。例如，衍射深度神经网络已被用于 3D 全息成像，利用波分复用同时处理不同的光谱通道。[72] 作为光谱多样性的补充，轨道角动量 (OAM) 模式复用通过酉变换将 OAM 模式与空间深度相结合，引入了一个深度可控的维度，使得在单个五层网络中重建多个全息图成为可能。这些设计共同表明，将复用维度与片上制造相结合，将使衍射硬件从单任务原型转变为高容量、多任务处理器，为根据特定应用约束选择最佳平台奠定基础。[73] [74] [75] [76] [12]

综合硬件格局可知，平台选择本质上是在静态效率与动态适应性之间进行的受限优化。传统超

表面作为静态的”一次性写入”器件,其光学特性在制造完成后即被固定,尽管具备强大的波前整形能力,但这一特性严重限制了其在动态场景中的灵活性。同样,当前的片上衍射神经网络架构一旦完成训练和物理结构制造便固定不变,若无昂贵的重新制造过程,便无法适应新任务。虽然这些静态平台利用光传播的并行性,使衍射深度神经网络在计算速度和能效方面相比电子对应方案实现了数量级的提升,但这种性能伴随着关键的脆弱性。近期分析表明,预训练模型可能易受物理上可行的对抗性攻击(如相位或幅度扰动)的影响,从而大幅降低分类准确率。因此,尽管静态平台针对专用任务最大化了能效,但缺乏制造后重构能力仍是需要抵御环境变化或对抗威胁的应用中的一个重大瓶颈。[77] [78] [51]

5 衍射光学网络中的波长复用与光谱带宽:多波长计算与色度约束

基于衍射的光学神经网络(ODNNs)作为固有的色散系统运行,其计算传递函数与照明波长严格耦合。这种色散源于固定物理结构所施加的相位调制与波长成反比缩放,导致当输入光谱偏离设计条件时,点扩散函数和衍射角发生偏移。[79]因此,针对特定单色光源优化的网络在宽带条件下运行时,其线性变换矩阵会发生漂移,除非采用窄带滤光片隔离颜色通道,否则将导致计算精度下降。虽然这种物理依赖关系对单任务操作施加了严格的带宽限制,但它同时也确立了波长复用机制的基础,使得不同的光谱分量能够在同一静态体积内触发独立的计算路径。理解这种色散的双重性质至关重要,因为它界定了非受控环境中的性能损失与利用光谱自由度实现多功能光学计算的机遇之间的边界。[31] [48] [52]

色度色散的物理原理表明,波长变化会改变相位延迟,但对于在单一波长下训练的衍射神经网络而言,暴露于光谱偏差时的实际后果是推理能力的严重退化。实证研究表明,试图使用浅层架构并行分类多个波长通常会导致性能不佳;例如,旨在区分三种可见光波长的单层和双层网络,其准确率分别仅为53%和60%,经常将不同的输入误分类为占主导地位的中间波长。这种失败不仅源于调制函数在整个光谱范围内的固有耦合,还源于制造约束,后者限制了可用于解析复杂光谱特征的衍射层数。与之形成鲜明对比的是,当散射条件严格符合单色训练环境时,这些针对单波长优化的系统仍能保持功能效用,即使在透过未知的随机漫射器成像时,也能实现超过78%的盲测准确率。然而,这种鲁棒性是脆弱的;比较分析表明,在相同的挑战性条件下,此类单色设计的性能显著低于其宽带对应方案,这凸显出单波长网络的高准确性取决于狭窄的光谱匹配,而这种匹配在实际的宽带照明场景中很少存在。[57] [60]

已发表的研究开发了消色差衍射网络,这些网络采用多层架构和硬件感知优化策略,旨在稳定宽光谱范围内的相位响应,从而抵消由色散引起的性能退化。一种主要策略是将多层薄膜与双尺度纳米结构相结合,利用多波长加权优化框架协同最小化反射率并校正波前像差;该设计已成功将光谱带宽扩展至140 nm,同时将低阶误差抑制至毫波长量级。另一种途径是采用双层超透镜架构和3D打印的多层结构,以几何方式突破单层器件的运营带宽限制。当制造变异性威胁性能时——特别是在短波长下,微小的尺寸误差会不成比例地影响推理精度——采用硬件在环(HIL)优化的混合设计提供了一种鲁棒的解决方案。通过在训练循环中嵌入可编程空间光调制器,HIL方法避开了不准

确的波前传播数学模型, 直接针对物理现实优化相位图案, 从而实现消色差扩展景深成像。在混合衍射光学领域, 硬件在环方法已被用于设计消色差扩展景深成像系统。通过将可编程空间光调制器直接集成到训练循环中, 所提出的网络允许针对物理现实优化相位图案, 而非依赖可能不准确的波前传播数学模型。[34] 然而, 这些缓解策略面临切实的界限: 增加衍射层数以改善多波长分类能力, 往往受限于聚合物材料特性以及高数值孔径物镜的工作距离, 这些因素限制了可制造的总高度和分辨率。因此, 尽管工程解决方案能显著抑制色散, 但必须在结构复杂性与可制造性之间进行严格的权衡, 以维持实际光学计算所需的高效宽带运行。[57] [80] [34] [81] [82]

衍射神经网络并非抑制色散, 而是利用光学自由度在单一物理结构中实现多个独立的计算功能。这种称为波长复用的策略, 使静态衍射元件能够通过为不同光谱波段编码独立功能, 同时执行不同的任务。该机制依赖于优化级联层的相位分布, 使得特定波长触发独特的线性变换, 从而无需机械重构即可将输入自由度映射到目标输出。虽然传统设计通常将器件划分为单独的区域, 这在单波长照明时会限制效率, 但多层自适应设计通过训练整个孔径在多个目标波长下同时正确聚焦或分类来克服这一局限。例如, 研究表明, 分配不同波长作为基带或载波频率, 可以使网络平衡学习率并执行多任务操作, 如并行图像识别, 其效能高于单任务基线。波长分复用已在 3D 衍射深度神经网络的全息成像中被利用, 以将色散依赖性作为一种功能性资源。该方法使不同波长能够在同一物理体积内触发独立操作, 促进复杂的任务, 如通过波长特异性信号处理进行 3D 全息重建。[72] 该配置将衍射系统固有的光谱敏感性从劣势转化为高通量计算的资源, 尽管这需要仔细的软硬件协同设计来管理任务准确性的权衡。最终, 以这种方式利用波长依赖性符合本章论点, 即色散为并行、多功能光学计算提供了关键的自由度。[83] [37] [84] [85] [50]

偏振复用进一步扩展了单个衍射网络的容量, 使其能够在相同的输出视场中同时实现多个复值线性变换, 这是在将波长作为计算自由度使用的基础上建立的。由此产生的设计利用了光的矢量特性, 其中不同的输入和输出偏振态作为独立通道, 用于执行目标检测或分类等编程任务, 而无需改变底层衍射架构。证据表明, 将这些任务集成到一个系统中, 与部署多个专用子系统相比, 在速度、紧凑性和成本效益方面具有显著优势, 仅需在各层之间添加易于获得的线性偏振器作为预确定的超参数。为了实现更高的信息密度, 轨道角动量 (OAM) 模式复用可以与波长和偏振维度相结合, 通过深度可控的时空演化同时重建多个全息图。通过在多层光学衍射神经网络中利用多平面光转换, 实验报告已成功调制 OAM 模式和空间深度, 实现了高保真度的深度复用全息术。研究人员通过采用光学衍射神经网络来调制 OAM 模式和空间深度, 展示了轨道角动量深度复用全息术, 并取得了高保真度的结果。[76] 这些先进的方案表明, 色散依赖性既是需要缓解的限制因素, 也是更广泛策略的基础要素, 在该策略中融合多个物理维度以最大化静态光学处理器的功能吞吐量。[29] [76]

要实现这些高密度复用系统的多功能潜力 (其中对波长和偏振通道的精确控制至关重要), 需要专门的训练范式, 以弥合理想化模拟与实际硬件限制之间的差距。物理感知可微离散协同设计通过在反向传播过程中保持梯度链, 解决了真实光学器件非均匀、模拟特性的问题。与标准量化不同, 该框架采用 Gumbel-Softmax 等技术来施加物理边界约束, 确保可训练的相位参数遵守周期性限制 (例如限制在 $[0, 2\pi]$ 范围内), 同时适应器件特有的非单调响应。[45] 与之相辅相成的是, 基于神经网络的设计方法利用衍射积分的卷积模拟, 针对特定光谱范围 (如太赫兹波段) 优化衍射元件。这些

算法能够生成反直觉的相位图, 将辐射重定向至复杂的强度分布, 从而提供超越传统确定性全息术的解决方案。最终, 这些层的设计涉及为统计任务迭代调整复值透射系数, 这一过程本质上将网络的最终功能与训练期间使用的照明光谱紧密关联。通过将这些物理现实直接嵌入优化循环, 研究人员可以构建出能够执行精确多波长计算的鲁棒静态结构。[45] [63] [86]

物理感知优化为衍射网络建立了结构蓝图, 然而要提升其计算表达能力和鲁棒性, 必须解决固有的线性约束和环境敏感性问题。一种策略是集成非线性光子元件, 直接在光域内实现激活函数; 例如, 谐振器为此提供了有利的非线性行为, 但也引入了对温度波动和机械振动的脆弱性, 从而可能导致性能下降。相比之下, 干涉仪擅长操纵相位和振幅以进行复杂计算, 但仍易受相位变化影响, 需要精确对准。为了在不单纯依赖脆弱的硬件非线性性的情况下缓解此类不稳定性, 集成学习策略已被应用于无源衍射深度神经网络 (D²NN)。通过对基模型进行空间特征工程多样化, 并利用多个独立训练网络的并行处理, 该光学架构显著提升了统计推断和泛化能力, 超越了单一定性层所能达到的水平。这些方法共同将静态物理结构从脆弱的单任务处理器转变为更具弹性的计算基底, 在考虑更广泛的系统级应用之前, 平衡了增强功能性与制造精度及环境稳定性等实际挑战之间的权衡。[33] [87]

要在高风险环境中部署衍射光学神经网络, 最终必须权衡其固有的物理优势与当前的精度局限。尽管数字卷积神经网络在原始分类指标上可能仍优于光学系统, 但全光衍射分类器在实时、能效推理方面具有独特优势, 使其在对速度和功耗有严苛约束的应用中极具吸引力。这种权衡在自动驾驶等新兴方案中尤为明显: 衍射架构旨在通过对 RGB 场景进行直接的全光处理而无需数字预处理, 从而提升大规模数字模型的延迟表现与计算效率。在自动驾驶背景下, 已有研究提出利用衍射神经网络进行全光分割, 直接处理 RGB 场景而无需数字预处理, 以期提高延迟和计算效率。[36] 这一硬件转型的驱动力还来自集成化衍射光子计算单元, 相较于电子器件, 其具备超宽带宽和大规模并行处理能力, 尽管此类系统的扩展常受限于可编程组件的尺寸与能耗挑战。历史上, 首批全光衍射深度神经网络系统利用被动 3D 打印层展示了超低延迟和低功耗优势, 但其运行受限于静态硬件实现的严格约束。为在保持高效的同时克服这种刚性, 最新进展引入了具有学习结构化照明的多功能衍射处理器; 通过将照明图样作为可训练参数, 这些系统能够复用静态衍射层, 在分类与计算成像等独立任务间快速切换。因此, 尽管宽带色散仍是单任务精度的挑战, 但它同时也为多功能光学计算提供了必要的自由度, 使衍射网络成为无标记生物医学分析和资源受限边缘计算领域的变革性技术。[7] [36] [38] [49] [41]

6 衍射神经网络的应用: 成像、分类、分割与模式识别

被称为衍射深度神经网络 (D2NN) 的全光学机器学习框架, 通过将神经网络权重编码到衍射层的物理厚度中, 以光速执行推理。[54] 与受数据传输瓶颈和晶体管延迟限制的电子处理器不同, D2NN 利用波在自由空间中的传播, 在信号穿过系统时即时执行模拟计算。该架构已在多类图像分类中得到实验验证, 特别是在 MNIST 手写数字数据集等标准基准测试中展示了高精度。在一项工作在可见光波段的典型实现中, 基于 SiO₂ 衬底制备的五层 D2NN 在推理阶段无需任何电子计算, 即在预留测试集上实现了 91.57% 的盲分类准确率。除数字识别外, 该能力还扩展至字母图像识别; 在对不

同字母数据集进行分类时,多通道衍射设计相较于传统单通道架构显示出显著的准确率提升。进一步拓展这一能力,近期研究开发了使用特定波长(如 $10.6\ \mu\text{m}$)的非线性全光学实现,以及能够进行复杂物体识别的可见光超表面系统。尽管这些演示确立了单一功能任务的基础成熟度,但它们主要作为概念验证基准;从这些受控光学环境向通用计算的转变,仍有赖于克服显著的仿真到现实差距及环境敏感性。[88] [89] [64] [90]

衍射光学神经网络 (DONNs) 在延迟和能耗方面的基本物理优势,是其得以应用的主要驱动力,这一优势超越了标准数据集所确立的分类基准。与依赖电子输运和电阻发热的电子电路不同,DONNs 利用光子被动执行计算,从而能够以光速进行推理,并显著降低功耗需求。这种光子硬件加速提供了超宽带宽和大规模并行性,解决了在传统硅基平台上扩展人工神经网络时固有的资源瓶颈。研究表明,衍射深度神经网络 (D2NNs) 在计算速度和能效方面相较于其电子对应器件已展现出数量级的提升,确立了其在高速、低功耗应用中的可行性。[91] [92] 然而,尽管集成光子电路为构建紧凑且兼容 CMOS 的计算单元提供了一条充满希望的路径,但在空间利用率以及控制相位调制器相关的能耗成本方面仍面临挑战。这些物理效率使得 DONNs 成为特定高吞吐量任务的有力解决方案,但也凸显了被动光学速度与可编程部署所需的控制复杂性之间的权衡。[13] [51] [38]

为了将计算密度扩展到简单的强度调制之外,多项研究开发了利用衍射系统延迟和能量优势的复用策略。偏振复用是一种技术,它通过将数据编码到不同的输入和输出偏振态中,使单个衍射网络能够在相同的输出视场中同时执行多个复值任意线性变换。[29] 该实现允许检测、分类等各种机器视觉任务集成在一个紧凑的系统内,与采用多个专用子系统相比,提供了更高的通用性和成本效益。与可能需要架构改变的空间或波分复用方法不同,偏振复用主要需要添加线性偏振片,这些偏振片可以灵活地与其他自由度耦合,以进一步增加容量。作为补充,轨道角动量 (OAM) 模式复用提供了一种通过利用涉及波长和偏振的物理维度的独立性来重建多个全息图的独特策略。通过设计通过幺正变换同时调制 OAM 模式和空间深度的光学衍射神经网络,可以实现用于大容量全息术的深度可控时空演化。此外,OAM 编码的衍射网络已证明能够利用 OAM 频谱分析对 MNIST 等数据集执行全光并行分类,但这目前需要具有高灵敏度的干涉仪探测器以管理信号损耗。虽然这些复用方法显著提高了信息容量,但它们引入了分类精度与输出效率之间的权衡,这表明尽管理论带宽巨大,但实际部署在探测器鲁棒性和信号完整性方面仍面临挑战。[29] [76] [93]

超越通用分类,衍射神经网络在解决衍射极限和色差等基础物理约束的专用成像任务中表现卓越。为实现超分辨,这些系统利用光学超振荡,即通过相干波的精确干涉产生的快速亚波长空间变化,从而在不具备荧光显微镜相关光毒性的情况下,实现超越传统阿贝 - 瑞利极限的远场成像。[94] [95] 同样,单片衍射元件通过放宽孔径尺寸与带宽之间的权衡来解决消色差成像问题;例如,超轴棱镜簇可产生与波长无关的贝塞尔光束以确保宽带一致性,尽管这通常需要通过牺牲聚焦效率来换取图像复原质量的提升。一种单片集成超轴棱镜簇通过将倾斜平面波转换为宽带均匀离轴贝塞尔光束,解决了消色差成像的约束。该设计由几个具有不同视场角的超轴棱镜组成,使超构相机能够在拼接后的 10° 视场内实现消色差成像,其角分辨率接近衍射极限透镜的水平。[96] 为进一步推动技术成熟,混合设计采用了硬件在环方法,其中可编程空间光调制器与电子图像信号处理进行端到端联合优化。该策略将光学硬件视为黑箱,利用零阶进化策略修正纯数学模型所遗漏的物理偏差,从而

实现鲁棒的扩展景深成像。[34] 这些应用表明,虽然光学衍射神经网络 (ODNN) 为特定光学瓶颈提供了独特的解决方案,但其最有效的实现往往依赖于光学预处理与计算后处理的协同设计。[35] [96] [34]

混合光电子卷积神经网络 (CNNs) 作为一种务实的架构应运而生,它将初始计算推入无源光学领域,同时保留电子灵活性以进行复杂决策,旨在弥合理论效率与实际部署之间的差距。在该设计中,优化的衍射元件直接在光学域中处理对颜色敏感的核心或前端特征提取,解决了单色滤波固有的信息丢失问题,并大幅减轻了电子硬件的计算负担。这种分工对于自动驾驶等对延迟敏感的应用尤为宝贵,因为光学处理在无需纯数字模型那样高功耗的情况下提供了速度优势。作为对该混合策略的补充,压缩感知系统利用机器学习算法最大限度地减少数据收集需求,使用针对特定任务的光学组件(如棱镜阵列或数字微镜器件)来实现传感矩阵。这些系统表明,即使存在光学模糊或较低的信噪比,它们仍能实现与传统成像相当的分类精度,同时所需的探测器单元数量大幅减少。此外,并行编码叠层成像系统展示了衍射原理如何克服生物医学显微镜中的扩展障碍,通过采用无序工程表面实现高通量、即插即用式的成像,从而消除了对精密机械扫描的需求。与这些成像和分类范式不同,物理信息衍射神经网络已应用于全光安全方案,能够实时解密散斑密文。通过近似散射介质的逆传输矩阵,这些网络能够在光学域中直接从散斑场中检索秘密图像,从而消除了传统方法中因光电转换和后处理带来的计算延迟。尽管这些架构成功缓解了功耗、数据量和机械稳定性方面的特定局限性,但它们往往依赖于体光学元件或特殊制造工艺,凸显了系统紧凑性与性能之间持续的权衡,这为开发能够动态更新这些静态光学权重的可重构材料奠定了基础。[31] [43] [97] [42]

新兴硬件平台利用可重构材料,允许在制造后更新权重,以克服固定衍射阵列的静态局限性。数字化相变材料异质结堆栈实现了具有可重构性的透射式衍射光学神经网络,通过利用光子极高的并行度和低静态能耗,支持计算机视觉等高吞吐量、节能的机器学习处理应用。或者,磁光衍射深度神经网络利用蒙特卡洛优化,结合随机权重更新和权重翻转,实现在磁光层中的实时可重构学习,其中候选配置根据梅特罗波利斯准则被接受或拒绝,从而在不使用导数的情况下降低损失。与这些设计不同,二维光子晶体衍射光学神经网络 (PhC-DONNs) 实现了片上光学并行分类方案,具备多波长并行处理能力。通过建立波长-衍射联合调制模型,该架构克服了传统单波长模式片上衍射网络的固有局限性,在图像和视频分类任务中表现出卓越的性能。尽管取得了这些进展,基于集成可重写超表面的片上衍射光学神经网络仍面临仿真与现实之间的差距,限制了其相对于电子基线的即时部署可行性。这种差异源于制造误差,但这些系统的可重写特性促进了原位训练程序,以补偿相位和功率偏差。虽然这些机制解决了早期设计的僵化问题,但物理缺陷的持续存在表明,仅靠可重构性并不能完全解决通用部署所需的全部挑战。[98] [99] [53] [30]

借助动态硬件更新的潜力,多功能衍射处理器现已实现单设备多任务学习,使物理系统能够在无需重新训练或机械重构的情况下执行不同的推理操作。这种能力依赖于软硬件协同设计,其中照明模式或超表面排列在优化过程中被视为可训练参数。例如,最近的框架将“学习到的”结构化照明纳入网络设计,使得在固定衍射层复用的同时,能够迅速切换于 MNIST 分类、Fashion-MNIST 识别和计算成像等任务之间。类似地,超表面赋能的架构利用超高神经元密度和并行性,支持自由配置的多任务功能,有效解决了传统电子系统中存在的内存-处理器瓶颈。通过光衍射物理实现深度学

习, 这些系统证明单个光学平台可以处理从视觉识别到波束整形的各种应用。然而, 尽管这些概念验证演示突显了显著的灵活性, 但也强调了当前的过渡阶段: 虽然专用多功能性已可实现, 但通用部署仍受限于定义 ODNN 研究持续挑战的环境敏感性和仿真到现实的差距。[41] [37]

尽管展示了多任务学习的能力, 衍射深度神经网络从实验室原型向广泛采用的技术转变, 仍受到理论设计与物理鲁棒性之间持久差距的限制。虽然这些系统因超低延迟和高并行光学计算能力而备受赞誉, 但其实际部署在环境稳定性和制造精度方面面临重大障碍。光子架构通常利用非线性行为来实现必要的激活函数, 然而谐振器等特定组件对外部扰动 (如温度波动和机械振动) 极为敏感, 这会导致性能下降。此外, 虽然衍射元件提供了可扩展的并行处理能力, 但它们引入了噪声和像差, 从而损害计算精度, 且实现所需的高精度制造既具挑战性又昂贵。尽管研究已验证全光分类在专门诊断任务 (如使用集成深度学习模型从胸部 X 射线中识别 COVID-19) 中的可行性, 但这些成功目前仅凸显了一个利基应用领域, 而非通用就绪状态。因此, 尽管近光速推理的基础潜力已确立, 但广泛采用目前仍受限于确保相位变化稳定性的复杂控制机制的需求, 以及整合能在受控环境外可靠运行的鲁棒、微型化光子电路的持续困难。[33] [100] [49]

7 衍射神经网络研究中的争议与未决辩论

衍射神经网络研究中的一个核心争论在于: 这些系统究竟是提供了真正的计算优势, 还是仅仅作为既定光学原理的复杂工程展示。支持者认为, 模拟光计算具有固有的并行性、能效和低延迟特性, 使其特别擅长处理物体分类和机器视觉等大规模计算任务, 而数字系统在这些任务中常面临瓶颈。这一观点得到了衍射深度神经网络 (D2NN) 等框架的支持; 该类框架利用深度学习算法来设计无源衍射面上的光 - 物质相互作用, 从而无需持续的电子功耗即可实现光速下的特定任务推理。[54] 此外, 基于集成芯片的方法旨在通过利用超宽带和高密度集成, 克服传统硅光子电路中存在的占用面积和能耗的二次方增长问题。然而, 批评者指出, 要实现精确的调制能力, 往往需要繁琐耗时的设计过程和复杂的制造工艺, 这些实际困难常常抵消了上述理论上的增益。目前, 光衍射神经网络 (ODNN) 研究在这一权衡问题上尚未达成共识, 因为报道的性能指标往往依赖于特定的基准数据集和仿真条件, 而非基本的物理极限; 部分分析表明, 纯光学层中非线性激活函数的缺失, 在与强大的电子后端配合时可能会阻碍优化。[48] [101] [38] [102]

验证计算优势的主张受到一个关键障碍的阻碍, 即所谓的”仿真到现实差距”(simulation-to-reality gap)。该差距反映了理想化标量衍射模型预测的性能与实际硬件结果之间的差异, 其根源在于制造公差和材料非理想性。[3] [103] 尽管使用传输矩阵法等方法进行的数值模拟能够直接预测光学响应, 但逆设计过程往往依赖于在物理原型中并不成立的假设。片上实现的证据表明, 这一差距具体源于制造过程中引入的误差, 因此需要采用相位和功率校正等算法补偿策略来恢复功能。此外, 假设完美层对准的标准训练协议未能考虑组装的机械现实; 然而, 在训练阶段引入随机失准变量 (一种称为”免疫训练”的技术), 可以显著提高针对严重层间位移的误差容限。[23] 许多实验演示中对线性材料的依赖也引入了光学损耗, 必须仔细管理这些损耗以维持信噪比, 这与无损耗的理论模型形成对比。因此, 报道的衍射系统与电子系统之间的大部分性能差异可能反映了这些有利的仿真

假设, 而非固有的物理限制; 这表明, 在严格的实验验证考虑到散射、吸收和制造变异之前, 所宣称的能量和速度优势仍然被夸大了。[18] [53] [23] [1] [104]

端到端可微训练定义了一种范式, 其中反向传播直接流经衍射积分以优化光学层, 理论上能够实现高通量的全光处理。然而, 当引入离散器件映射时, 所提出的网络遭遇了基本的梯度链断裂, 因为物理离散化破坏了标准算法所假设的光滑可微性。虽然理想化模拟表明, 此类网络利用无源衍射层可扩展至数千亿个连接, 但实际部署揭示了数值建模与物理硬件之间的不匹配, 这源于非均匀的器件响应和模拟量约束。具体而言, 光学器件表现出非单调行为和周期性相位限制, 而均匀的数字计算无法捕捉这些特性, 因此需要采用如 Gumbel-Softmax 等物理感知框架, 以实现灵活的可微离散映射。[45] 此外, 由于物理衍射层缺乏固有的非线性, 依赖基于计算机仿真的训练并假设激活函数, 造成了仿真与现实之间的差距, 这往往需要混合电子辅助或复杂的制造工艺来近似弥补。这些局限性凸显出, 尽管端到端训练提供了理论上的速度优势, 但其实际优越性仍取决于解决理想化梯度链与模拟光学硬件不规则性之间的脱节问题。[45] [1] [70] [105]

ODNN 研究目前面临着单功能优化设计与通用可训练系统之间的根本架构分歧。单功能架构, 如色差校正衍射透镜, 利用迭代算法优化特定宽带聚焦任务的沟槽高度, 在该单一应用中实现卓越性能, 但缺乏适应性。相比之下, 早期的通用方法往往产生显著的复杂性开销, 需要移动光学元件或不同的硬件系统才能在任务之间切换。为了解决这种僵化性, 新兴的多波长衍射深度神经网络利用光谱维度, 无需机械重构即可在多个数据库上执行并行分类, 有效地将不同输入编码到单独的光谱通道中。此外, 具有学习结构照明的多功能处理器将照明图案作为可训练参数, 使得衍射层能够重用, 从而快速在分类和成像任务之间切换。然而, 这些灵活的多层设计在制造公差和光机组装方面引入了实际挑战, 因为它们对层间错位高度敏感。最近的进展通过接种疫苗策略缓解了这一问题, 该策略在训练期间模拟随机位移, 但核心张力依然存在: 最大化特定任务的效率与维护更广泛应用所需的通用性之间的权衡, 这一权衡直接影响接下来讨论的物理可实现性。[106] [75] [41] [23]

物理实现的瓶颈最终制约了这些衍射系统的落地, 使得专用设计与灵活设计之间的理论架构之争退居其次。尽管光子谐振器为光学激活函数提供了有利的非线性行为, 但其性能本质上仍易受温度波动和机械振动等环境干扰的影响。这种敏感性也延伸至照明条件: 实际部署要求对非相干光进行稳健处理, 然而大多数理论框架依赖于理想的准单色假设, 而这些假设在受控实验室之外很少成立。此外, 将这些网络与标准半导体工艺集成构成了一个关键障碍, 因为目前的演示大多局限于概念验证装置, 而非可扩展且兼容 CMOS 的平台。当试图融合多种光学功能时, 挑战更为严峻, 这往往需要复杂的编码方案或繁琐的重建算法, 从而削弱了实际的简易性。因此, 尽管衍射光学神经网络有望通过光子计算实现无源能效和低延迟推理, 但在不陷入固定架构局限和对准敏感性的前提下实现完全可编程的可重构性, 仍然是一个重大的工程壁垒。[33] [71] [38] [107] [13]

针对前文所述的硬件瓶颈与集成难题, 新兴的反向观点提出, 衍射神经网络 (DONNs) 无需依赖复杂的多层可训练架构即可发挥效能。其中一种途径是采用极简主义 DONNs, 其利用简单的光学配置实现高效的计算能力, 在图像分类任务中展现出鲁棒性与可扩展性, 且避免了深层、全可训练堆栈所带来的复杂性开销。例如, 一种极简光学衍射神经网络采用两级量化像素级光学编码, 在无需深层、全可训练堆栈复杂性的情况下实现了鲁棒的图像分类。[66] 另一种方案是端到端光电框架,

它将衍射元件重新定义为固定的无源编码器,而非主动计算机;在此类无透镜成像系统中,设计好的掩模对光进行调制以供下游算法重建,从而引发了一个根本性问题:光学层本身究竟是在执行计算,还是仅仅在对数据进行预处理?在无透镜成像系统(如掩模调制技术的最新进展所述)中,设计的掩模充当固定的无源编码器,调制光线以用于下游算法重建,而非执行主动计算。[108] 尽管通过衍射积分进行的标准端到端可微分训练已实现了全光学泛化至未见过的散射环境,允许在不重新训练的情况下透过未知扩散体进行重建,但这种能力往往基于理想化的标量衍射模型。这些模型常常忽略材料色散、制备引起的表面粗糙度以及对准误差,导致显著的仿真与现实差距。为解决这一问题,先进的训练方案现在在学习阶段引入随机对准误差作为连续变量,有效地为网络“接种”,使其在面对物理装配公差时仍能保持性能。此外,试图通过在单层不同空间区域训练不同任务来增加灵活性的做法,面临着严峻的物理面积限制,通常将此类复用系统限制为仅能同时实现两到三种功能。综上所述,这些进展表明,虽然光学衍射神经网络(ODNNs)具有理论上的速度优势,但其实际优越性仍取决于如何解决极简无源编码与复杂、理想化主动计算的脆弱性之间的矛盾。[109] [66] [110] [108] [23]

8 衍射神经网络的瓶颈与未来轨迹: 迈向混合电光系统与可扩展光学 AI

当前,将实验室原型转化为可部署的光学人工智能系统所取得的进展,受到静态衍射神经网络固有刚性的阻碍。这些网络作为“一次性写入”硬件,无法在不进行机械干预或完全重新制造的情况下实现动态自适应。尽管近期的多波长设计已证明并行任务处理可以缓解部分吞吐量限制,但這些系统在可重构性方面仍受根本性制约,通常需要为不同的计算目标配置独立的硬件实例。除了缺乏灵活性之外,物理实现还引入了严重的性能差距;在较短波长下,衍射元件尺寸的微小制造偏差即可大幅降低分类精度,而材料约束限制了可行光学层数的增加,进一步加剧了这一挑战。[111] 此外,谐振器等光子组件对环境扰动(如温度波动和机械振动)表现出极高的敏感性,这会破坏相位关系并损害推理的可靠性。这些瓶颈——静态功能、制造敏感性和环境不稳定性——为全光方法确立了明确的边界,迫切需要向混合电光协同设计战略转变,以实现实际部署所需的鲁棒性。[75] [57] [33] [77]

一个关键的仿真到现实差距(定义为模型从理想化数值环境转移到实际硬件时观察到的性能下降)阻碍了衍射神经网络从理论设计向物理部署的转化。虽然仿真通常假设使用具有高空间相干的准单色照明,但实际应用需要处理非相干和部分相干光,导致光场在网络层中演化的方式存在根本性差异。[71] 这种差异因制造引起的表面粗糙度而加剧,后者引入了未建模的相位误差,使得推理精度显著低于数字预测结果。此外,紧凑的多层设计还面临层间反射和像素间相互作用的额外约束;尽管这些效应在低折射率材料中可能微不足道,但在高折射率系统中却成为重大障碍,限制了分析模型的保真度。解决这些瓶颈要求超越静态设计,转向制造感知训练和硬件在环优化,其中在线重训练可以补偿物理缺陷并恢复设计功能。这些物理现实强调了接下来讨论的混合电光策略的必要性,旨在通过整合电子灵活性与光学速度来减轻此类刚性。[53] [71] [70] [112]

混合光电协同设计已成为解决静态硬件中可重构性与非线性瓶颈的主导策略。该架构将静态衍

射层与负责非线性激活和逻辑运算的可重构电子层相结合; 其中, 静态衍射层利用光传播固有的并行性和低延迟特性, 实现高通量特征提取。通过将这类计算密集型的非线性任务卸载至电子器件, 此类系统在保持显著能效优势的同时, 有效缓解了全光学硬件的刚性局限。代表性实施方案包括基于数字编码超表面阵列的可编程衍射深度神经网络, 该类方案保留了电子控制的灵活性, 从而克服了无源器件固定网络架构的束缚。此外, 研究表明, 在全光学多层网络末端附加卷积神经网络可实现联合训练, 其中电子组件引入 ReLU 和 Sigmoid 等必要的非线性函数, 以增强系统整体性能。尽管纯光学方法在任意调制和精确控制方面面临挑战, 但这种混合路径有效弥合了光学速度与电子适应性之间的差距, 为通过可编程材料实现进一步的动态控制机制奠定了基础。[28] [48] [28] [105]

为克服静态硬件限制, 近期研究通过引入可编程材料与在线学习机制, 赋予了系统动态适应能力。可编程超表面被定义为能够通过外部控制信号改变相位分布的动态光学表面, 从而解决了被动衍射层的刚性问题。例如, 磁光衍射深度神经网络利用法拉第效应, 通过磁畴的磁化方向调制光相位, 无需复杂的微纳加工工艺, 即可实现在线学习技术, 动态重构网络以校正对准或制造误差。除了这种线性可重构性外, 集成可调谐非线性激活函数还克服了固定光学非线性瓶颈。该系统采用 WO_3 薄膜等光致变色材料, 利用紫外激发诱导价间电子转移, 可逆地改变薄膜的复振幅分布, 从而模拟自适应的类神经元操作。[113] 尽管此类物理感知训练框架有助于将计算机训练的模型部署到可重构硬件上, 但这些设计主要代表了一种可行的近期发展路径: 它们利用光学速度进行推理, 同时保留电子灵活性以实现快速更新和误差校正, 而非实现完全自主的全光编程。[114] [113] [13]

可编程材料解决了可重构性问题, 然而衍射系统的工作带宽仍受限于波长相关的相位延迟, 因此需要先进的设计策略以支持高光谱应用。多元件超表面系统通过利用局部单元中依赖于照明角度的相位延迟, 有效解耦了角度自由度, 从而在不依赖复杂本征角度色散的情况下实现鲁棒的全息成像。研究人员利用单层自由曲面超表面在可见光波段演示了一种多波长消色差偏转器, 实现了宽带操作且无需依赖复杂的本征角度色散。[115] 与这种结构方法相辅相成, 数据驱动的反向设计框架利用可微分神经模拟器, 将超表面几何结构直接映射到光谱响应, 从而实现光学编码器与重建网络的联合端到端优化。与传统未优化的滤波器相比, 该方法在光谱保真度和噪声鲁棒性方面展现出显著改进。在散射环境中, 带宽扩展的关键优势得到了进一步证实: 宽带单像素衍射网络在穿过未知随机扩散体时的盲测准确率达到了约 88.53%, 明显优于单色设计, 后者的准确率存在约 10% 的亏损。这些发现强调, 波长复用为信息处理容量提供了显著优势, 而要大规模实现这些设计, 则需将物理制造约束直接嵌入训练循环, 以确保实验可行性。[116] [55] [60]

弥合持续的仿真与现实差距, 要求优化协议从理想化的数值模拟演变为物理感知训练, 即将硬件约束直接嵌入学习循环中。一个主要挑战在于, 直接将离散模拟器件响应映射到衍射光学神经网络 (DONN) 系统会破坏反向传播所需的梯度链, 因为光学组件表现出非均匀、非单调的行为, 这与稳定的数字计算不同。物理感知可微离散协同设计通过利用 Gumbel-Softmax 等技术来解决这一问题, 实现尊重物理周期性和器件特定范围的完全可微映射, 从而缩小训练与部署之间的差异。[45] 除了离散映射外, 制造引起的相位误差和波前像差仍是降低介电超表面保真度的关键瓶颈。像差自适应学习通过将生成的波前畸变 (如来自泽尼克多项式的畸变) 纳入每个训练批次来缓解这些问题。[117] 这种配置迫使模型适应各种未知的像差, 而不是针对单一理想状态进行优化, 从而在实验上稳

定了分类精度,使其免受材料收缩或热膨胀引起的变化影响。通过这些不可避免的物理缺陷与光学设计共同优化,研究人员可以降低对制造精度的要求,同时确保稳健的性能,这是迈向混合光电系统的必要步骤,后者被视为可扩展光学 AI 的可行前进道路。[45] [117] [118]

即使采用将约束直接嵌入训练循环的物理感知优化协议,ODNN(光学深度神经网络) 研究仍缺乏标准化的基准数据集,无法验证其进展是否超越了狭窄的 2D 空间成像任务。当前的高保真资源虽然严谨,但仅限于固定的细胞样本和基于宽场 (widefield) 的架构,未能涵盖更广泛部署所需的时空动力学或体积反卷积挑战。这一数据缺口因在线原位训练中的严重计算瓶颈而加剧: 在 MNIST 等高维数据集中补偿系统误差所需的处理时间,往往超过了受温度和振动影响的实验装置的稳定性窗口。因此,研究人员通常不得不依赖离线误差补偿而非动态自适应,这凸显了迈向成熟的关键障碍。通过统一的评估协议和高效的训练策略来解决这些局限性,对于将衍射神经网络从静态实验室原型转变为可扩展光学 AI 愿景中的混合电光系统至关重要。[119] [120]

近期的工程策略优先考虑迁移学习和多功能处理器设计,以弥合静态硬件局限性与动态功能需求之间的差距。迁移学习通过引入部分可重构的光学单元来解决固定物理结构的僵化问题,使预训练层能够适应新任务而无需完全重新制造;例如,此类架构的数值模拟已证明,在 MNIST 数据集上可实现多任务处理,分类准确率达到 98.8%。这些设计验证了极简光学配置可有效部署于特定推理应用,包括全息数据存储和图像分类,尽管可重构性有限,但仍能利用其固有的计算效率。虽然早期的全光学衍射深度神经网络成功展示了利用自由空间光互连实现的超低延迟和高并行度,但它们仍受限于固定的硬件架构,无法进行后加工更新。因此,完全可编程的全光网络的实现尚未在实验中达成,主要归因于在介电超表面中大规模集成动态、低损耗相位调制所面临的物理挑战。尽管基于全介电超表面的设计通过减小元件尺寸至波长尺度以下,为小型化和提高空间神经元密度提供了一条路径,但目前它们仅作为概念验证步骤,而非完整的解决方案。因此,当前的短期轨迹倾向于采用混合电光协同设计来注入动态功能,而将完全可编程的全光系统目标留给长期的材料和制造突破。[78] [121] [49] [68]

与传统的卷积神经网络相比,全光学衍射分类器在实时和能效推理方面具有显著优势,使其在对速度要求关键的应用中具有吸引力,尽管其在原始准确率方面目前仍有不足。虽然衍射深度神经网络 (D2NNs) 通过高度并行的光学计算提供了超低延迟和低功耗,但其实际部署面临重大瓶颈,包括制造引起的相位误差、多个衍射平面间的对准挑战以及有限的操作带宽。此外,当前研究表明,在静态衍射层的不同区域训练不同任务受到面积限制,通常将单个器件的功能限制为仅两到三个固定功能。这些僵化问题凸显了纯光学方法为何不足以支持可扩展的多功能 AI,从而强化了本章的核心论点,即混合电光架构是最可行的发展路径。通过利用光学速度处理线性子任务,同时依靠电子灵活性进行误差校正和重构,此类混合系统可以克服推理速度与功能适应性之间的固有权衡。[7] [40] [110]

9 结论

本综述综合了光学衍射神经网络 (ODNNs) 的研究现状, 探讨了其作为区别于传统电子学的独立计算范式的可行性这一核心问题。物理、训练和硬件领域呈现的证据表明, ODNNs 不仅充当光加速器, 更是独特的物理计算机, 其中衍射定律决定了计算的表达能力。通过将电子权重矩阵替换为空间变化的相位分布, 这些系统利用光的固有并行性, 以光速执行线性变换并实现极低的能耗。该架构为解决冯·诺依曼瓶颈提供了极具吸引力的方案, 能够针对实时图像分类、全光加密和压缩感知等特定任务实现超低延迟推理。然而, 现有文献明确指出, 这种优势目前具有领域特异性; ODNNs 在线性或预定义操作的吞吐量和能效方面表现优异, 但由于根本性的物理限制, 它们尚未构成对电子处理器的通用替代方案。

理想化数学模型与物理现实之间的张力构成了阻碍广泛部署的主要局限。一个关键障碍是仿真到现实的差距: 由于制造公差、表面粗糙度和材料色散, 标量衍射模型预测的性能在物理原型中会下降。尽管硬件在环 (HIL) 优化和对准误差“免疫”等技术显示出弥合这一差距的潜力, 但它们也凸显了当前设计的脆弱性。此外, 无源衍射层的固有线性引入了非线性瓶颈, 限制了网络在不借助外部干预的情况下解决复杂问题的能力。这一局限性, 结合大多数已制备超表面及 3D 打印元件的静态特性, 导致了缺乏动态计算环境所需可重构性的“一次性写入”硬件。因此, 纯全光系统容易受到温度波动和机械振动等环境扰动的干扰, 这些扰动可能破坏相位关系并损害推理的可靠性。

展望未来, ODNN 研究的发展趋势似乎正从追求完全全光通用计算机转向混合光电协同设计。可扩展光学 AI 最可行的路径是利用衍射层的速度和并行性进行线性特征提取, 同时将非线性激活函数和自适应控制卸载给电子组件。这种混合方法缓解了静态硬件的僵化性, 并允许进行错误纠正和动态任务切换, 而纯光系统目前无法支持这些功能。此外, 未来的进展取决于采用物理感知训练范式, 将制造约束和设备非理想因素直接嵌入损失景观中, 确保所设计的网络对制造偏差具有鲁棒性。为了验证这些进展, ODNN 研究还必须建立标准化的基准测试协议, 超越狭窄的 2D 成像任务, 以评估真实条件下的时空动力学和体数据处理能力。总之, 虽然 ODNNs 已从理论概念发展为展示独特物理优势的实用实验室原型, 但其向稳健、可部署技术的转型将依赖于将光学速度与电子灵活性相结合, 从而创建能够在受控实验室环境之外有效运行的弹性系统。

参考文献

- [1] Xing Lin, Y. Rivenson, N. Yardimci, Muhammed Veli, Yilin Luo, M. Jarrahi, and A. Ozcan. All-optical machine learning using diffractive deep neural networks. *Science*, 2018. doi: 10.1126/science.aat8084. URL <https://www.semanticscholar.org/paper/5c7e5248d9eb7f373f10277410bf8506160907ea>.
- [2] Md. Sadman Rahman, Yuhang Li, Xilin Yang, Shiqi Chen, and A. Ozcan. Massively parallel and universal approximation of nonlinear functions using diffractive processors. *eLight*,

2025. doi: 10.1186/s43593-025-00113-w. URL <https://www.semanticscholar.org/paper/437456e03c66e4ff07fe02ba65d9c80ec6d16d22>.
- [3] Marshall Lindsay, Scott D. Kovaleski, Andy G. Varner, Charlie T. Veal, Derek Anderson, Stanton R. Price, and S. Price. Cooperative optimization of neural-network-based diffraction simulations and benchtop spatial light modulators. *Defense + Commercial Sensing*, 2024. doi: 10.1117/12.3013482. URL <https://www.semanticscholar.org/paper/6fd25f7413884a789f96e6ec5f1a3158e39b82a1>.
 - [4] Zhibo Sun, Zheng-Nan Yuan, Vigneshwaran Swaminathan, V. Vashchenko, Olena Vashchenko, A. Cheung, Le Lu, H. Kwok, and A. Srivastava. Reconfigurable geometrical phase spatial light modulator using short-pitch ferroelectric liquid crystals. *Advanced Optical Materials*, 2023. doi: 10.1002/adom.202300561. URL <https://www.semanticscholar.org/paper/cdadaaf04821df3f3f81b30caa20d07e13d7919b>.
 - [5] Kohei Yamamoto and Hiroyuki Yanagisawa. Physics-aware-trained diffractive deep neural networks. *NanoScience + Engineering*, 2023. doi: 10.1117/12.2675468. URL <https://www.semanticscholar.org/paper/f3c23f10b318c35a28be747c0b5982a2ba4cae5f>.
 - [6] Xiaohang Sheng, Shaodong Zhou, Dong Zhao, Li Ding, Kun Huang, Guanxue Wang, Songlin Zhuang, and Qingqing Cheng. Cross-scale multiplane holograms with decoupled input–output sampling for vehicle display. *Advanced Photonics Nexus*, 2025. doi: 10.1117/1.apn.5.1.016005. URL <https://www.semanticscholar.org/paper/60ff8b23856d75d40e0ae82f27b38ed55ea545ab>.
 - [7] Norihide Sagami, Yueyun Weng, Cheng Lei, Ryosuke Oketani, and Kotaro Hiramatsu. All-optical classification of real biomedical cell images using a diffractive neural network: a simulation study. *Optics Letters*, 2025. doi: 10.1364/ol.593231. URL <https://www.semanticscholar.org/paper/56f68ce02f6656afc6453655e57a5ceb11c970e0>.
 - [8] S. Zarei. Scalability of on-chip diffractive optical neural networks, 2024. URL <https://www.semanticscholar.org/paper/f7b7631268f17b1f868015df0bd08ef57904024d>.
 - [9] Zhijian Liang, Chenxuan Xiang, Shuyuan Xiao, Jumin Qiu, Jie Li, Qiegen Liu, C. Zou, and Tingting Liu. Metasurface-based all-optical diffractive convolutional neural networks. *Journal of Applied Physics*, 2025. doi: 10.1063/5.0323145. URL <https://www.semanticscholar.org/paper/6664d1be229dafa7a65e2b7fb1243f29084bb0a4>.
 - [10] Xiaokun Teng, Wankai Tang, Xiao Li, and Shi Jin. Baseband-free end-to-end communication system based on diffractive deep neural network. *IEEE Transactions on Wireless Commu-*

- nications*, 2025. doi: 10.1109/twc.2025.3632886. URL <https://www.semanticscholar.org/paper/0518ca584481f922f473ca4f510a272c0470b0cb>.
- [11] Junjie Shao, Lingxiao Zhou, Sze-Yan Yeung, T. Lei, Wanlong Zhang, and Xiaocong Yuan. Pulmonary nodule detection and classification using all-optical deep diffractive neural network. *Life*, 2023. doi: 10.3390/life13051148. URL <https://www.semanticscholar.org/paper/bb2489d876aa7ecf8853de5b1b0a96e4d303d1cd>.
 - [12] Yong-Liang Xiao. Optical phase dropout in diffractive deep neural network. *Optics Letters*, 2020. doi: 10.1364/ol.428761. URL <https://www.semanticscholar.org/paper/e328fde07bd3248d2019054a4cdbf0f61e519369>.
 - [13] Ruiyang Chen, Yingjie Li, Minhan Lou, Jichao Fan, Yingheng Tang, B. Sensale-Rodriguez, Cunxi Yu, and Weilu Gao. Physics-aware machine learning and adversarial attack in complex-valued reconfigurable diffractive all-optical neural network. *Laser & Photonics Reviews*, 2022. doi: 10.1002/lpor.202200348. URL <https://doi.org/10.1002/lpor.202200348>.
 - [14] K. V. Sreekanth, Qing Yang Steve Wu, Sambhu Jana, Ranjan Singh, and Jinghua Teng. Tunable directional thermal emission using a phase change material-based multilayer structure. *Nanoscale Horizons*, 2025. doi: 10.1039/d5nh00367a. URL <https://www.semanticscholar.org/paper/651bc92f1107c0493ad1bbd5b17a87c6afcd5c10>.
 - [15] Yizhi Zhang, Jianan Shen, Ben Tsai, Xuanyu Sheng, Zedong Hu, Xinghang Zhang, and Haiyan Wang. Tin-au/hfo2-au multilayer thin films with tunable hyperbolic optical response. *Small Methods*, 2024. doi: 10.1002/smt.202400087. URL <https://www.semanticscholar.org/paper/9a1b2a83a8808286e05751a8b9d0c358db980fa9>.
 - [16] X. Hong, S. Feng, Honglian Guo, and Chuanbo Li. High-efficiency full-phase modulation of a terahertz wave based on a dielectric metasurface. *Laser Physics Letters*, 2019. doi: 10.1088/1612-202x/ab2121. URL <https://www.semanticscholar.org/paper/daae7316e4c7ae9bdb38113c97df5335526ae908>.
 - [17] Nithin Koilkonda, M. Rangula, P. Paul, and K. Kandasamy. Transmissive all-dielectric metasurface for beam-splitting in the ka-band. *2025 Third International Conference on Microwave, Antenna and Communication (MAC)*, 2025. doi: 10.1109/mac64480.2025.11140514. URL <https://www.semanticscholar.org/paper/1be9e89c440a82b7b2379d782f9270e149df388f>.
 - [18] Taigao Ma, Mingqian Ma, and L. J. Guo. Optical multilayer thin film structure inverse design: From optimization to deep learning. *iScience*, 2024.

- doi: 10.1016/j.isci.2025.112222. URL <https://www.semanticscholar.org/paper/42e53c9c7630eb735f9a67f329c948423910cd8d>.
- [19] Yufei Liu, Weizhu Chen, Xin-Ke Wang, and Yan Zhang. All dielectric metasurface based diffractive neural networks for 1-bit adder. *Nanophotonics*, 2024. doi: 10.1515/nanoph-2023-0760. URL <https://www.semanticscholar.org/paper/916246d3fb00fde0d8f1223f5343447e6d964168>.
- [20] Aakash Warke, Aonan Zhang, and A. Lvovsky. Quantum-limited imaging using diffractive optical neural networks, 2026. URL <https://www.semanticscholar.org/paper/7caf7c29ac69aa12038f926409fb469f65ebeb2a>.
- [21] Xian Zhang, Mingxu Piao, Hongxu Ma, Junsong Wang, Weishuai Wang, Yuhao Song, Zonglin Liang, and Bo Zhang. Physics-prior and deep learning fusion for single-plane diffractive imaging in frequency-spatial domains. *Optics Express*, 2025. doi: 10.1364/oe.579297. URL <https://doi.org/10.1364/oe.579297>.
- [22] Tao Fang, Li Jingwei, Xiang Zhang, and Xiaowen Dong. A novel nonlinear generalization training framework for hybrid optical diffractive deep neural networks. *Optics Express*, 2021. doi: 10.1364/oe.446890. URL <https://doi.org/10.1364/oe.446890>.
- [23] Deniz Mengü, Yifan Zhao, Nezih Tolga Yardimci, Yair Rivenson, Mona Jarrahi, and Aydogan Özcan. Misalignment resilient diffractive optical networks. *Nanophotonics*, 2018. doi: 10.1515/nanoph-2020-0291. URL <https://doi.org/10.1515/nanoph-2020-0291>.
- [24] Boru Xu, Shuyang Xie, Zefeng Huang, Yuetong Fang, Xin Wang, Bo-Xun Cheng, Shaoliang Yu, Zhongrui Wang, and Renjing Xu. Sparse transmission in diffractive deep neural networks via optical spiking neurons. *Optica*, 2026. doi: 10.1364/optica.576204. URL <https://doi.org/10.1364/optica.576204>.
- [25] Marshall Lindsay, S. Kovaleski, Andy G. Varner, Charlie T. Veal, J. Weber, Derek Anderson, Stanton R. Price, and S. Price. Impact of data variety on physics-informed neural network lens design. *Defense + Commercial Sensing*, 2023. doi: 10.1117/12.2661856. URL <https://www.semanticscholar.org/paper/51de1bca941d1af3bf94055650b240aa6f62a8c9>.
- [26] Ying Li, Li Deng, and Meijun Qu. Near-field microwave holographic imaging using a metamaterial-based diffraction neural network with angular spectrum-assisted computation. *Microwave and optical technology letters (Print)*, 2025. doi: 10.1002/mop.70313. URL <https://www.semanticscholar.org/paper/bcb65da442e68964b4bd28cc5a0d4b1802b62163>.

- [27] S. Zarei and A. Khavasi. Realization of optical logic gates using on-chip diffractive optical neural networks. *Scientific Reports*, 2022. doi: 10.1038/s41598-022-19973-0. URL <https://www.semanticscholar.org/paper/52cf7f6ca6ab9c9c241b36bca83c962551dd3480>.
- [28] Che Liu, Qian Ma, Z. Luo, Q. Hong, Qiang Xiao, Hao Chi Zhang, Long Miao, W. Yu, Q. Cheng, Lianlin Li, and T. Cui. A programmable diffractive deep neural network based on a digital-coding metasurface array. *Nature Electronics*, 2022. doi: 10.1038/s41928-022-00719-9. URL <https://www.semanticscholar.org/paper/7efb4f8ff9aa6f5e9691e9392b539298ef46ca04>.
- [29] Jingxi Li, Yi-Chun Hung, Onur Kulce, Deniz Mengü, and Aydoğan Özcan. Polarization multiplexed diffractive computing: all-optical implementation of a group of linear transformations through a polarization-encoded diffractive network. *Light: Science & Applications*, 2022. doi: 10.1038/s41377-022-00849-x. URL <https://www.semanticscholar.org/paper/04c16f79232a1dba281da8a2626e1933bcb10641>.
- [30] Yuanyuan Zhang, Kuo Zhang, Pei Hu, Daxing Li, and Shuai Feng. Multi-wavelength diffractive optical neural network integrated with 2d photonic crystals for joint optical classification. *Nanophotonics*, 2025. doi: 10.1515/nanoph-2025-0168. URL <https://www.semanticscholar.org/paper/3ba89be3519e5be4bb45c0cbc483536e1db8bb63>.
- [31] Julie Chang, V. Sitzmann, Xiong Dun, W. Heidrich, and Gordon Wetzstein. Hybrid optical-electronic convolutional neural networks with optimized diffractive optics for image classification. *Scientific Reports*, 2018. doi: 10.1038/s41598-018-30619-y. URL <https://www.semanticscholar.org/paper/b06d7f7742ed94078f512011968ae123e576b59f>.
- [32] Lin Wu and Ziyang Zhang. Only-train-electrical-to-optical-conversion (oteoc): simple diffractive neural networks with optical readout. *Optics Express*, 2022. doi: 10.1364/oe.462370. URL <https://doi.org/10.1364/oe.462370>.
- [33] Svetlana N. Khonina, Nikolay L. Kazanskiy, and . . . Exploring types of photonic neural networks for imaging and computing—a review. *Nanomaterials*, 2024. doi: 10.3390/nano14080697. URL <https://doi.org/10.3390/nano14080697>.
- [34] Samuel Pinilla, Seyyed Reza Miri Rostami, I. Shevkunov, V. Katkovnik, and K. Egiazarian. Hybrid diffractive optics design via hardware-in-the-loop methodology for achromatic extended-depth-of-field imaging. *Optics Express*, 2022. doi: 10.1364/oe.461549. URL <https://www.semanticscholar.org/paper/00af565d66563cb83347d304c37313cc2dfa0902>.
- [35] Hang Chen, Sheng Gao, Haiou Zhang, Zejia Zhao, Zhengyang Duan, Gordon Wetzstein, and Xing Lin. Superresolution imaging using superoscillatory diffractive neural networks. *Ad-*

- vanced Photonics*, 2024. doi: 10.1117/1.ap.6.5.056004. URL <https://www.semanticscholar.org/paper/5c084d119ead6e728fa85d3ea4d10ab49295829b>.
- [36] Yingjie Li, Daniel Robinson, Weilu Gao, and Cunxi Yu. All-optical segmentation via diffractive neural networks for autonomous driving. *arXiv.org*, 2026. doi: 10.48550/arxiv.2602.07717. URL <https://www.semanticscholar.org/paper/7bf766d777d62c780d0c10658b79c74f0ae3b0af>.
 - [37] Yudong Tian, Haifeng Xu, Yuqing Liu, Xiangyu Zhao, Jingzhu Shao, Jie Cheng, and Chongzhao Wu. Metasurface-empowered freely-arrangeable multi-task diffractive neural networks. *Photonics Research*, 2025. doi: 10.1364/prj.576203. URL <https://www.semanticscholar.org/paper/7991c4cd79e5e08f9ca67e6a5fd5b509b9c2f4ac>.
 - [38] H. Zhu, J. Zou, H. Zhang, Y. Z. Shi, S. Luo, N. Wang, H. Cai, L. Wan, B. Wang, X. D. Jiang, J. Thompson, X. Luo, X. Zhou, L. Xiao, W. Huang, L. Patrick, M. Gu, L. Kwek, and A. Liu. Space-efficient optical computing with an integrated chip diffractive neural network. *Nature Communications*, 2022. doi: 10.1038/s41467-022-28702-0. URL <https://www.semanticscholar.org/paper/585c02f3ea677e72535f4ea2af006230e5892445>.
 - [39] Tong Fu, Xinqiao Lin, Jiacheng Li, Gang Luo, Hangyu Zheng, Zhengrui Ji, Deen Wang, X. Yuan, Yuhai Li, and Y. Geng. Dual-wavelength differential diffractive network for all-optical object classification. *Laser & Photonics Reviews*, 2025. doi: 10.1002/lpor.202500433. URL <https://doi.org/10.1002/lpor.202500433>.
 - [40] Ruotong Wang and Junhe Zhou. Robustness of parallel subnetwork-filtered diffractive deep neural networks. *Optics Express*, 2026. doi: 10.1364/oe.598903. URL <https://doi.org/10.1364/oe.598903>.
 - [41] Jiajun Zhang, Kexin Wen, Yishun Wang, Xiang Wang, Jiaqi Li, and Weibing Lu. Optical multi-task learning using a multifunctional diffractive processor with "learned" structured illumination. *Optics Letters*, 2026. doi: 10.1364/ol.591818. URL <https://doi.org/10.1364/ol.591818>.
 - [42] Jiaan Gan, Yong Yang, Siwei Zhu, Shengjiang Chang, and Xiaocong Yuan. High-speed all-optical speckle decryption empowered by a physics-informed diffractive neural network. *Advanced Photonics Nexus*, 2026. doi: 10.1117/1.apn.5.1.016010. URL <https://www.semanticscholar.org/paper/c54c11ac9f68c6de49d119f78ec15b47d4e1ac69>.
 - [43] Brian J. Redman, Amber L. Dagel, Meghan A. Galiardi, C. LaCasse, T. Quach, and G. Birch. Performance evaluation of two optical architectures for task-specific compressive classification.

- Optical Engineering: The Journal of SPIE*, 2020. doi: 10.1117/1.oe.59.5.051404. URL <https://www.semanticscholar.org/paper/58f461486dd3c713b61d5ed0d374aa0d680dc31c>.
- [44] Y. Rivenson, Yichen Wu, and A. Ozcan. Deep learning in holography and coherent imaging. *Light: Science & Applications*, 2019. doi: 10.1038/s41377-019-0196-0. URL <https://www.semanticscholar.org/paper/d8b77c7eef21591067997d5ffaeca249bbbd25bc>.
- [45] Yingjie Li, Ruiyang Chen, Weilu Gao, and Cunxi Yu. Physics-aware differentiable discrete codesign for diffractive optical neural networks. *2022 IEEE/ACM International Conference On Computer Aided Design (ICCAD)*, 2022. doi: 10.1145/3508352.3549378. URL <https://www.semanticscholar.org/paper/1716c059da55f246fb44c95094c2c92781424124>.
- [46] Qingming Liao, Haoqiang Wang, ZeXin Feng, Mengmeng Li, Yi Luo, and Xianglong Mao. Differentiable design of freeform diffractive optical elements for beam shaping by representing phase distribution using multi-level b-splines. *Optics Express*, 2024. doi: 10.1364/oe.533298. URL <https://doi.org/10.1364/oe.533298>.
- [47] K. Ma, Qiang Song, Jian Shen, Yi Li, and Yuan Chen. Design and fabrication of metasurface optical elements (moe) for direct time of flight application. *International Computing Imaging Conference*, 2025. doi: 10.1117/12.3056838. URL <https://www.semanticscholar.org/paper/ce310725aab37bfbf840b13764b457bfc524918c>.
- [48] Kaiyang Cheng, Cong Deng, Fengyu Ye, Hongqiang Li, Fei Shen, Yuanchen Fan, and Yubin Gong. Metasurface-based image classification using diffractive deep neural network. *Nano-materials*, 2024. doi: 10.3390/nano14221812. URL <https://www.semanticscholar.org/paper/614a70af75ba590cc98dfc4c8aeec02322b5906f>.
- [49] Yichen Sun, M. Dong, Mingxin Yu, Xiaolin Liu, and Lianqing Zhu. A review of diffractive deep neural networks. *Journal of the Optical Society of America B*, 2023. doi: 10.1364/josab.497148. URL <https://doi.org/10.1364/josab.497148>.
- [50] Yingjie Li, Ruiyang Chen, B. S. Rodriguez, Weilu Gao, and Cunxi Yu. Multi-task learning in diffractive deep neural networks via hardware-software co-design. *arXiv.org*, 2020. URL <https://www.semanticscholar.org/paper/88f87b34acdb11cf20ad16d6fbdd5399e8617f8f>.
- [51] Yingjie Li and Cunxi Yu. Late breaking results: Physical adversarial attacks of diffractive deep neural networks. *Design Automation Conference*, 2021. doi: 10.1109/dac18074.2021.9586204. URL <https://doi.org/10.1109/dac18074.2021.9586204>.
- [52] Filipe Camarneiro, Manuel J. L. F. Rodrigues, João Cunha, Aamod Shanker, Ana Dias, Filipe S. Alves, and D. Aguiam. Hardware-in-the-loop free space optical computing and

- optimization of polychromatic multilevel diffractive optics for imaging. *2025 25th Anniversary International Conference on Transparent Optical Networks (ICTON)*, 2025. doi: 10.1109/icton67126.2025.11125227. URL <https://doi.org/10.1109/icton67126.2025.11125227>.
- [53] S. Zarei. Programmable diffractive deep neural networks enabled by integrated rewritable metasurfaces. *Scientific Reports*, 2024. doi: 10.1038/s41598-025-19638-8. URL <https://www.semanticscholar.org/paper/0e4597e0c87cca5d2b71233828098072cce414df>.
- [54] Quanzhou Long, Lisheng Yao, Junjie Shao, F. Yeung, Lingxiao Zhou, Wanlong Zhang, and Xiaocong Yuan. Tunable photoinduced liquid crystal retarders for all-optical diffractive deep neural networks. *ACS Photonics*, 2024. doi: 10.1021/acsp Photonics.4c01284.s001. URL <https://doi.org/10.1021/acsp Photonics.4c01284.s001>.
- [55] Rongzhou Chen, Haitao Nie, Shu Zhu, Yaping Zhao, Chutian Wang, and Edmund Y. Lam. Inverse design of metasurface for spectral imaging, 2025. URL <https://www.semanticscholar.org/paper/76a83ea3baed75ad88b7f0782eb9a694a330c853>.
- [56] Ting Ma, Xianjin Liu, Qiwen Bao, Bolun Zhang, and J. Xiao. Neural network-assisted end-to-end inverse design for polarimetric microspectrometer. *Advanced Materials & Technologies*, 2025. doi: 10.1002/admt.202401999. URL <https://www.semanticscholar.org/paper/81807791bd6fda88a9b1d39fef86a92f599a2ec4>.
- [57] Ying Zhi Cheong, Litty Thekkekkara, M. Bhaskaran, B. del Rosal, and Sharath Sriram. Broadband diffractive neural networks enabling classification of visible wavelengths. *Advanced Photonics Research*, 2024. doi: 10.1002/adpr.202300310. URL <https://www.semanticscholar.org/paper/34d7ba5c285f38e34ad058f6b2f4e7e55c2fc224>.
- [58] Tiankuang Zhou, Lu Fang, Tao Yan, Jiamin Wu, Yipeng Li, Jingtao Fan, Huaqiang Wu, Xing Lin, and Qionghai Dai. In situ optical backpropagation training of diffractive optical neural networks. *Photonics Research*, 2020. doi: 10.1364/prj.389553. URL <https://doi.org/10.1364/prj.389553>.
- [59] S. Behroozinia and Qing Gu. Leveraging multiplexed metasurfaces for multi-task learning with all-optical diffractive processors. *Nanophotonics*, 2024. doi: 10.1515/nanoph-2024-0483. URL <https://www.semanticscholar.org/paper/16ed08b493742343f057e5e1cb729cf3c85471f1>.
- [60] Bijie Bai, Yuhang Li, Yilin Luo, Xurong Li, Ege Cetintas, Mona Jarrahi, and Aydogan Ozcan. All-optical image classification through unknown random diffusers using a single-pixel diffractive network. *Light: Science & Applications*, 2022.

- doi: 10.1038/s41377-023-01116-3. URL <https://www.semanticscholar.org/paper/44b0e870cc19b77b3af6950a66c37fd57acc0558>.
- [61] Sheng Gao, Hang Chen, Yichen Wang, Zhengyang Duan, Haiou Zhang, Zhi Sun, Yuan Shen, and Xing Lin. Super-resolution diffractive neural network for all-optical direction of arrival estimation beyond diffraction limits. *Light: Science & Applications*, 2024. doi: 10.1038/s41377-024-01511-4. URL <https://www.semanticscholar.org/paper/f2d4d1a1571020070d3b8d2b2c3aeda13cb93bec>.
- [62] Qunli Wu and Lei Jin. Location-aware diffractive neural network based on polarization-dependent metasurface. *International Conference on Information Optics and Photonics*, 2025. doi: 10.1117/12.3086084. URL <https://doi.org/10.1117/12.3086084>.
- [63] P. Komorowski, Marta Kurowska, M. Kaluza, Patrycja Czerwińska, P. Zagrajek, and A. Siemion. Neural network-based design of two-focal-spot terahertz diffractive optical elements. *IEEE Transactions on Terahertz Science and Technology*, 2024. doi: 10.1109/tthz.2023.3344020. URL <https://www.semanticscholar.org/paper/0ee1313bd0d634f5bd393fe89b423ae05cd5ebe3>.
- [64] Yichen Sun, M. Dong, Mingxin Yu, Jiabin Xia, Xu Zhang, Yuchen Bai, Lidan Lu, and Lianqing Zhu. Nonlinear all-optical diffractive deep neural network with 10.6 μ m wavelength for image classification. *International Journal of Optics*, 2021:1–16, 2021. doi: 10.1155/2021/6667495. URL <https://www.semanticscholar.org/paper/4ba9e7e795e3a61da775e1bde30c8cb4a5159cb2>.
- [65] Erfan Ghapanvari and M. Salahshoor. Sensitivity and tolerance analysis of single-layer mgf2 and sio2 anti-reflection coatings. *Scientific Reports*, 2025. doi: 10.1038/s41598-025-33607-1. URL <https://www.semanticscholar.org/paper/270aeae23bf5eacb3a461b2535f4af080785221b>.
- [66] Xianjin Liu, Ting Ma, Qiwen Bao, Zhanying Ma, Guodong Gao, and Jun-Jun Xiao. Minimalist optical neural computing: Optical diffractive neural network by 2-level quantized pixel-wise optical encoding. *Laser & Photonics Review*, 2025. doi: 10.1002/lpor.202402303. URL <https://doi.org/10.1002/lpor.202402303>.
- [67] G. Abadias, E. Chason, J. Keckes, M. Sebastiani, G. Thompson, E. Barthel, G. Doll, C. Murray, C. Stoessel, and L. Martinu. Review article: Stress in thin films and coatings: Current status, challenges, and prospects. *Journal of Vacuum Science & Technology A: Vacuum, Surfaces, and Films*, 36(2), 2018. doi: 10.1116/1.5011790. URL <https://www.semanticscholar.org/paper/3668222c2f6d0fa9b8b51cecf7651ff7fc7f491a>.

- [68] Yufei Liu, Weizhu Chen, and Yan Zhang. All dielectric metasurface-based diffractive neural networks all optical computing. *SPIE/COS Photonics Asia*, 2023. doi: 10.1117/12.2688132. URL <https://doi.org/10.1117/12.2688132>.
- [69] T. Z. Minikhanov, E. Zlokazov, R. Starikov, and P. Cheremkhin. Measurement of phase modulation time dynamics of liquid crystal spatial light modulator. *Izmeritel'naya Tekhnika*, 2024. doi: 10.32446/0368-1025it.2023-12-35-39. URL <https://www.semanticscholar.org/paper/4cb4c136f864cac63be92654351ebdce2b2f7514>.
- [70] Shangli Zhou, Yingjie Li, Minhan Lou, Weilu Gao, Zhijie Shi, Cunxi Yu, and Caiwen Ding. Physics-aware roughness optimization for diffractive optical neural networks. *Design Automation Conference*, 2023. doi: 10.1109/dac56929.2023.10247715. URL <https://www.semanticscholar.org/paper/ab5c9eaf1dad8b72da43b27c4312bed466013b1>.
- [71] Matthew J. Filipovich, Aleksei Malyshev, and A. Lvovsky. Role of spatial coherence in diffractive optical neural networks. *Optics Express*, 2023. doi: 10.1364/oe.523619. URL <https://www.semanticscholar.org/paper/66d76eac8c5cb0c37d44c10bce479d8c301d113b>.
- [72] He Zhou, Haoqian Pu, Hao Xie, and Junhe Zhou. 3d holographic imaging using diffractive deep neural networks with wavelength division multiplexing. *2024 Asia Communications and Photonics Conference (ACP) and International Conference on Information Photonics and Optical Communications (IPOC)*, 2024. doi: 10.1109/acp/ipoc63121.2024.10809872. URL <https://doi.org/10.1109/acp/ipoc63121.2024.10809872>.
- [73] Mingzhu Song, Xuhui Zhuang, Lu Rong, and Junsheng Wang. Tilted-mode all-optical diffractive deep neural networks. *Micromachines*, 2024. doi: 10.3390/mi16010008. URL <https://doi.org/10.3390/mi16010008>.
- [74] Jiping Duan, Jinming Hu, Shengting Zhu, Bo Chen, Min Gu, and Yinan Zhang. On-chip integrated ultra-compact microscale optical logic operations based on diffractive neural networks. *ACS Photonics*, 2026. doi: 10.1021/acsp Photonics.5c02472. URL <https://doi.org/10.1021/acsp Photonics.5c02472>.
- [75] Zhengyang Duan, Hang Chen, and Xing Lin. Optical multi-task learning using multi-wavelength diffractive deep neural networks. *Nanophotonics*, 2022. doi: 10.1515/nanoph-2022-0615. URL <https://www.semanticscholar.org/paper/cdb2c928e087f4cd2b807836fd131089bf81a711>.
- [76] Zebin Huang, Yanliang He, Peipei Wang, Wenjie Xiong, Haisheng Wu, Junmin Liu, Huapeng Ye, Ying Li, Dianyuan Fan, and Shuqing Chen. Orbital angular momentum deep multiplexing

- holography via an optical diffractive neural network. *Optics Express*, 2022. doi: 10.1364/oe.447337. URL <https://doi.org/10.1364/oe.447337>.
- [77] Zhuoxuan Fan, Meng Zhang, Zihao Gan, Mengyue Chang, C Zhang, Z Liu, Jianming Lv, Kunsheng Xing, Zhuoqun Hu, Junbo Yang, and Huajie Hong. Cross-scale synergistic optimization for miniature meta-liquid hybrid zoom imaging. *Nanophotonics*, 2026. doi: 10.1002/nap2.70185. URL <https://doi.org/10.1002/nap2.70185>.
- [78] Hao Wu, Tingzhao Fu, Ping Liu, Wei Xu, Zhihong Zhu, and Jianfa Zhang. Transfer learning-based diffractive optical neural network. *Symposium on Novel Photoelectronic Detection Technology and Application*, 2026. doi: 10.1117/12.3109287. URL <https://doi.org/10.1117/12.3109287>.
- [79] Waqas A. Imtiaz and Abid Iqbal. Autoencoder-based nonlinear impairment mitigation in high-capacity four-channel wavelength division multiplexed long-haul optical communication systems. *Optical Engineering: The Journal of SPIE*, 2026. doi: 10.1117/1.oe.65.5.058106. URL <https://www.semanticscholar.org/paper/0e0d4c0c72b4017c2a9e8a0dfa651d7a886d1ee6>.
- [80] Liang Hong, Haoran Song, Lipu Zhang, and Xinyu Wang. Zernike correction and multi-objective optimization of multi-layer dual-scale nano-coupled anti-reflective coatings. *Modelling*, 2026. doi: 10.3390/modelling7010029. URL <https://www.semanticscholar.org/paper/c977f316916c59a12a847854a4eef6f49381b590>.
- [81] Yilin Wang, Qingbin Fan, and Ting Xu. Design of high efficiency achromatic metalens with large operation bandwidth using bilayer architecture. *Opto-Electronic Advances*, 2021. doi: 10.29026/oea.2021.200008. URL <https://doi.org/10.29026/oea.2021.200008>.
- [82] Chengfeng Pan, Hao Wang, Hao Wang, Hongtao Wang, Hongtao Wang, Parvathi Nair S, Qifeng Ruan, Simon Wredh, Yujie Ke, John You En Chan, Wang Zhang, Cheng-Wei Qiu, and Joel K. W. Yang. 3d-printed multilayer structures for high-numerical aperture achromatic metalenses. *Science Advances*, 2023. doi: 10.1126/sciadv.adj9262. URL <https://doi.org/10.1126/sciadv.adj9262>.
- [83] Chao Zuo and Qian Chen. Exploiting optical degrees of freedom for information multiplexing in diffractive neural networks. *Light: Science & Applications*, 2022. doi: 10.1038/s41377-022-00903-8. URL <https://www.semanticscholar.org/paper/e265d8653dabb3fa0068ab956b084f8f252bdbcf>.
- [84] Yuyao Chen, Yilin Zhu, Wesley A. Britton, and L. Dal Negro. Inverse design of ultracompact multi-focal optical devices by diffractive neural networks. *Optics Let-*

- ters, 2022. doi: 10.1364/ol.460186. URL <https://www.semanticscholar.org/paper/438f30f7d53e93e1f20e50ee62f1029f509ed4e5>.
- [85] Jing Su, Yafei Yuan, Chunmin Liu, and Jing Li. Multitask learning by multiwave optical diffractive network. *Mathematical Problems in Engineering*, 2020. doi: 10.1155/2020/9748380. URL <https://www.semanticscholar.org/paper/a8191fd687585196d26f1c0758b618c56e475696>.
- [86] Deniz Mengu, Y. Rivenson, and A. Ozcan. Scale-, shift- and rotation-invariant diffractive optical networks. *ACS Photonics*, 2020. doi: 10.1021/acsp Photonics.0c01583. URL <https://www.semanticscholar.org/paper/e21c4bb77ec29f0e6b14e6a98ab872b0dfedd2f5>.
- [87] Md. Sadman Rahman, Jingxi Li, Deniz Mengu, Y. Rivenson, and A. Ozcan. Ensemble learning of diffractive optical networks. *Light: Science & Applications*, 2020. doi: 10.1038/s41377-020-00446-w. URL <https://www.semanticscholar.org/paper/9f31d98e42fb579c04a4b4255b7bc65fd68bd49d>.
- [88] Huayi Sheng. Review of integrated diffractive deep neural networks. *Highlights in Science Engineering and Technology*, 2022. doi: 10.54097/hset.v24i.3957. URL <https://www.semanticscholar.org/paper/55cb8d7e1a77738c00ebb76beb0735dd764b33ab>.
- [89] Chen Hang, Jianan Feng, Minwei Jiang, Yiqun Wang, Jie Lin, Jiubin Tan, and Peng Jin. Diffractive deep neural networks at visible wavelengths. *Engineering*, 7(10):1483–1491, 2021. doi: 10.1016/j.eng.2020.07.032. URL <https://doi.org/10.1016/j.eng.2020.07.032>.
- [90] Yuanguo Zhou, Shan Shui, Yu Chen, Bingyang Liang, and Yijun Cai. Alphabetic image recognition based on multi-channel diffractive deep neural network. *Progress in Electromagnetics Research Symposium*, 2021. doi: 10.1109/piers53385.2021.9694760. URL <https://doi.org/10.1109/piers53385.2021.9694760>.
- [91] F. Ashtiani, M. Idjadi, T. Hu, S. Grillanda, D. Neilson, M. Earnshaw, M. Capuzzo, Rose Kopf, A. Tate, and A. Blanco-Redondo. A surface-normal photodetector as nonlinear activation function in diffractive optical neural networks. *APL Photonics*, 2023. doi: 10.48550/arxiv.2305.03627. URL <https://www.semanticscholar.org/paper/84ab1d075fa2777eb71a0a244042c0888c379d51>.
- [92] Haoyu Wang, Yanmin Zhu, and Tong Fu. All optical classification surpasses cascaded diffractive networks through dual wavelength differential modulation within a single layer architecture, 2025. URL <https://www.semanticscholar.org/paper/e9e6fc7353675c8e70b11e4ba8a931d959c2e912>.

- [93] Kuo Zhang, Kun Liao, Haohang Cheng, Shuai Feng, and Xiaoyong Hu. Advanced all-optical classification using orbital-angular-momentum-encoded diffractive networks. *Advanced Photonics Nexus*, 2023. doi: 10.1117/1.apn.2.6.066006. URL <https://www.semanticscholar.org/paper/63b863bcbec76876495f1ce52fe95a4ea501165e>.
- [94] Yishuo Tong, Danni Chen, Heng Li, and Bo Cao. A super-resolution reconstruction algorithm based on improved superoscillation. *Other Conferences*, 2020. doi: 10.1117/12.2576293. URL <https://www.semanticscholar.org/paper/82d2a6035efcb8431ad879c73da845ca84836a76>.
- [95] Mateusz Mazelanik, Adam Leszczyński, and Michał Parniak. Spectral superresolution using a quantum memory. *2023 Conference on Lasers and Electro-Optics Europe & European Quantum Electronics Conference (CLEO/Europe-EQEC)*, 2023. doi: 10.1109/cleo/europe-eqec57999.2023.10231830. URL <https://www.semanticscholar.org/paper/2e1509e125ee4acf4668fc1a0b06d488c9c8a8d7>.
- [96] Jianli Wang, Chengmiao Wang, Bin Wang, Yongting Deng, Yu Lin, Yeming Han, Lu Yao, Long Zhang, Dayu Li, Dejie Meng, Xiufeng Liu, Xiyu Li, Jan G. Korvink, and Yongbo Deng. Minimalist optical system for achromatic imaging within extended field of view based on monolithic integrated meta-axicon cluster. *Light: Science & Applications*, 2026. doi: 10.1038/s41377-026-02272-y. URL <https://www.semanticscholar.org/paper/54e53e2aba40ccb8b0f1fa5b22deb4dfe9614917>.
- [97] Shaowei Jiang, Chengfei Guo, Pengming Song, Niyun Zhou, Z. Bian, Jiakai Zhu, Ruihai Wang, Pei Dong, Zibang Zhang, Jun Liao, Jianhua Yao, B. Feng, Michael Murphy, and G. Zheng. Resolution-enhanced parallel coded ptychography for high-throughput optical imaging. *ACS Photonics*, 2021. doi: 10.1021/acsphotonics.1c01085. URL <https://www.semanticscholar.org/paper/c58188c40b895731d924f12170a8c95d9b248557>.
- [98] Ruiyang Chen, Jichao Fan, Cunxi Yu, and Weilu Gao. Digitized phase-change material heterostack for transmissive diffractive optical neural network. *Advanced Photonics Research*, 2024. doi: 10.1002/adpr.202400201. URL <https://www.semanticscholar.org/paper/70fc6876369c504d32731466ecc0f4f800daa3ee>.
- [99] Fatima ZAHRA CHAFI, Tomonao Matsuya, Hotaka Sakaguchi, Kanata Watanabe, and T. Ishibashi. Monte carlo optimization for real-time magnetic domain learning in magneto-optical diffractive deep neural networks. *Journal of the European Optical Society-Rapid Publications*, 2026. doi: 10.1051/jeos-2026026. URL <https://doi.org/10.1051/jeos-2026026>.
- [100] Albatoul S. Althenayan, Shada Alsalamah, S. Aly, T. Nouh, and A. A. Mirza. Detection and classification of covid-19 by radiological imaging modalities using deep learning techniques:

- A literature review. *Applied Sciences*, 2022. doi: 10.3390/app122010535. URL <https://doi.org/10.3390/app122010535>.
- [101] Deniz Mengu, Yifan Zhao, Anika Tabassum, M. Jarrahi, and Aydogan Ozcan. Diffractive interconnects: all-optical permutation operation using diffractive networks. *Nanophotonics*, 2022. doi: 10.1515/nanoph-2022-0358. URL <https://www.semanticscholar.org/paper/7e610be39d945a2ac2ad1afe66fefe66915511f0>.
 - [102] Deniz Mengü, Yi Luo, Yair Rivenson, and Aydogan Özcan. Analysis of diffractive optical neural networks and their integration with electronic neural networks. *IEEE Journal of Selected Topics in Quantum Electronics*, 2019. doi: 10.1109/jstqe.2019.2921376. URL <https://doi.org/10.1109/jstqe.2019.2921376>.
 - [103] Y. Jiao, Wenya Gao, Yanyu Gao, Bojian Shi, Fangkui Sun, Qi Jia, Rui Feng, Yongyin Cao, and W. Ding. Ultracompact and efficient on-chip diffractive neural networks through physics-constrained dual-optimization. *Fourteenth National Conference on Photonics*, 2025. doi: 10.1117/12.3084472. URL <https://www.semanticscholar.org/paper/1943d443bb02190e95b7fe101edcadeacbd2199f>.
 - [104] Deniz Mengu, Yilin Luo, Y. Rivenson, Xing Lin, Muhammed Veli, and A. Ozcan. Response to comment on "all-optical machine learning using diffractive deep neural networks". *arXiv.org*, 2018. URL <https://www.semanticscholar.org/paper/94f3822c453a2ab6d44c59f1f60026acb15739af>.
 - [105] Guannan Wang, Xiaofei Zang, Teng Zhang, Zhiyu Tan, Ziqing Guo, Yiming Zhu, Xianzhong Chen, and Songlin Zhuang. High-capacity directional information processor using all-optical multilayered neural networks. *Science Advances*, 2025. doi: 10.1126/sciadv.adu0904. URL <https://www.semanticscholar.org/paper/da2b8700882d2dde6f3d32f5018c17c0df41016b>.
 - [106] Peng Wang, Nabil Mohammad, and R. Menon. Chromatic-aberration-corrected diffractive lenses for ultra-broadband focusing. *Scientific Reports*, 2016. doi: 10.1038/srep21545. URL <https://www.semanticscholar.org/paper/ec7361fab96328e584523cb899c2afc3b027ccc3>.
 - [107] Jumin Qiu, Tingting Liu, Chenxuan Xiang, Tianbao Yu, Qiegen Liu, and Shuyuan Xiao. Integrated spectropolarimeter by metasurface-based diffractive optical networks. *Optica*, 2025. doi: 10.1364/optica.583686. URL <https://www.semanticscholar.org/paper/99916fcca704fb4d1c402da3aa3dd30bb1d6345a>.

- [108] Yangyundou Wang and Zhengjie Duan. Advances in mask-modulated lensless imaging. *Electronics*, 2024. doi: 10.3390/electronics13030617. URL <https://doi.org/10.3390/electronics13030617>.
- [109] Yunzhe Li and L. Tian. Computer-free computational imaging: optical computing for seeing through random media. *Light: Science & Applications*, 2022. doi: 10.1038/s41377-022-00725-8. URL <https://doi.org/10.1038/s41377-022-00725-8>.
- [110] Ziang Yin, Yao Yu, Jeff Zhang, and Jiaqi Gu. Multi-dimensional reconfigurable, physically composable hybrid diffractive optical neural network. *arXiv (Cornell University)*, 2024. doi: 10.48550/arxiv.2411.05748. URL <https://doi.org/10.48550/arxiv.2411.05748>.
- [111] Hotaka Sakaguchi, Takumi Fujita, Jian Zhang, S. Sumi, H. Awano, Hirofumi Nonaka, and T. Ishibashi. Development of fabrication techniques for magneto-optical diffractive deep neural networks. *IEEE transactions on magnetics*, 2023. doi: 10.1109/tmag.2023.3281842. URL <https://www.semanticscholar.org/paper/79f9fa0d7cb79a31d204ff1e2efb991c864fd2c6>.
- [112] Minhan Lou, Yingjie Li, Cunxi Yu, Berardi Sensale-Rodriguez, and Weilu Gao. Effects of interlayer reflection and interpixel interaction in diffractive optical neural networks. *Optics Letters*, 48(2):219, 2023. doi: 10.1364/ol.477605. URL <https://doi.org/10.1364/ol.477605>.
- [113] Xiaoguang Ma, Fangzhen Hu, Xi Chen, Zhecheng Qiu, Min Gu, and Qiming Zhang. Tunable nonlinear activation functions enabled by wo3 films for adaptive diffractive deep neural networks. *Laser & Photonics Reviews*, 19(24), 2025. doi: 10.1002/lpor.202500558. URL <https://doi.org/10.1002/lpor.202500558>.
- [114] Hotaka Sakaguchi, Riku Oya, Satoshi Sumi, Hiroyuki Awano, Hirofumi Nonaka, Fatima Zahra Chafi, and Takayuki Ishibashi. Development of online learning technique for magneto-optical diffractive deep neural networks. *Journal of Physics: Conference Series*, 3161(1):012042, 2026. doi: 10.1088/1742-6596/3161/1/012042. URL <https://doi.org/10.1088/1742-6596/3161/1/012042>.
- [115] Taewon Choi, Chulsoo Choi, Junseo Bang, Youngjin Kim, Hyunwoo Son, Changhyun Kim, Junhyeok Jang, Yoonchan Jeong, and Byoungcho Lee. Multiwavelength achromatic deflector in the visible using a single-layer freeform metasurface. *Nano Letters*, 24(35):10980–10986, 2024. doi: 10.1021/acs.nanolett.4c02995. URL <https://doi.org/10.1021/acs.nanolett.4c02995>.
- [116] Dashuang Liao, Chan Wang, Xiaokang Zhu, Liqiao Jing, Min Li, and Zuojia Wang. Global designed angle-multiplexed metasurface for holographic imaging enabled by the diffractive

- neural network. *Progress In Electromagnetics Research*, 183:81–90, 2025. doi: 10.2528/pier25052305. URL <https://doi.org/10.2528/pier25052305>.
- [117] Ikuo Hoshi, Koki Wakunami, Yasuyuki Ichihashi, and Ryutaro Oi. Wavefront-aberration-tolerant diffractive deep neural networks using volume holographic optical elements. *Scientific Reports*, 15(1), 2025. doi: 10.1038/s41598-024-82791-z. URL <https://doi.org/10.1038/s41598-024-82791-z>.
- [118] Sajjan Shrestha, Adam Overvig, Ming Lu, Aaron Stein, and Nanfang Yu. Multi-element metasurface system for imaging in the near-infrared. *Applied Physics Letters*, 122(20), 2023. doi: 10.1063/5.0141881. URL <https://doi.org/10.1063/5.0141881>.
- [119] Ning Xu, Cilong Zhang, Yuegang Fu, and Qiaofeng Tan. High-fidelity super-resolution microscopy datasets spanning multispectral to hyperspectral domains via diffractive optics. *Scientific Data*, 13(1), 2026. doi: 10.1038/s41597-026-07467-x. URL <https://doi.org/10.1038/s41597-026-07467-x>.
- [120] Tingzhao Fu, Yubin Zang, Yuyao Huang, Zhenmin Du, Honghao Huang, Chengyang Hu, Minghua Chen, Sigang Yang, and Hongwei Chen. Photonic machine learning with on-chip diffractive optics. *Nature Communications*, 14(1), 2023. doi: 10.1038/s41467-022-35772-7. URL <https://doi.org/10.1038/s41467-022-35772-7>.
- [121] Toshihiro Sakurai, Tomoyoshi Ito, and Tomoyoshi Shimobaba. Diffractive deep-neural-network-based classifier for holographic memory. *Photonics*, 11(2):145, 2024. doi: 10.3390/photonics11020145. URL <https://doi.org/10.3390/photonics11020145>.